Mathématiques appliquées aux sciences sociales

Notes de cours

Table des matières

1 Fonctions **3**

2 Suites **11**

3 Systèmes d'équations linéaires **21**

4 Matrices **28**

5 Dérivation et optimisation **37**

Introduction

Ces notes constituent le support du cours de mathématiques appliquées aux sciences sociales à Sciences Po pour l'année universitaire 2026–2027. Les trois premiers chapitres rappellent les notions fondamentales nécessaires pour aborder la suite du programme de première année. Les chapitres suivants introduisent progressivement de nouveaux outils et leurs applications.

Le choix est fait de présenter les mathématiques à travers des situations concrètes. L'accent est mis sur les applications économiques et sociales, avec également des exemples issus de la physique, de la biologie ou de l'informatique. L'objectif est de montrer comment les mathématiques permettent de modéliser, d'analyser et de mieux comprendre le monde qui nous entoure.

Pourquoi faire des mathématiques à Sciences Po ?

1. Les mathématiques sont **utiles pour étudier des situations concrètes**, en économie et plus largement en sciences sociales.
2. Elles sont **au cœur de bouleversements récents**, comme l'essor de l'intelligence artificielle ou les sciences du climat.
3. Elles constituent enfin une **formation pour mieux réfléchir** : poser clairement un problème, raisonner rigoureusement et vérifier ses conclusions.

Plan du cours

Après les trois chapitres de rappels (fonctions, suites, systèmes linéaires), le cours s'organise autour de quatre grands chapitres :

1. Matrices ;
2. Dérivation et optimisation ;
3. Mesures d'inégalités, qui introduit l'intégrale ;
4. Graphes et réseaux.

Remarque. Matrices + optimisation = ChatGPT ! Les grands modèles de langage reposent essentiellement sur des produits de matrices dont on optimise les coefficients. On reviendra sur ce point à la fin du chapitre sur les matrices.

Repères de logique et de raisonnement

— L'implication $P \Rightarrow Q$ signifie : si P est vraie, alors Q est vraie. Sa réciproque est $Q \Rightarrow P$ et sa contraposée est $\neg Q \Rightarrow \neg P$.

— Une équivalence $P \Leftrightarrow Q$ réunit les deux implications $P \Rightarrow Q$ et $Q \Rightarrow P$.

— Nier « pour tout x, $P(x)$ » revient à affirmer « il existe x tel que $P(x)$ est fausse ». Nier « il existe x tel que $P(x)$ » revient à affirmer « pour tout x, $P(x)$ est fausse ».

— Un raisonnement par l'absurde suppose la négation du résultat recherché et montre que cette hypothèse conduit à une contradiction.

— Une récurrence comporte une initialisation, une étape d'hérédité et une conclusion. Elle permet d'établir une propriété pour tout entier à partir d'un premier rang.

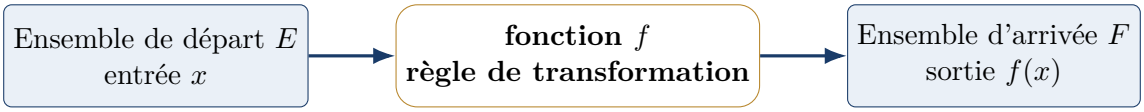
1 Fonctions

1.1 Rappels sur les fonctions

Une fonction est avant tout un *objet mathématique abstrait*. On peut la voir comme une machine : elle reçoit une entrée, lui applique une règle de transformation, puis produit une sortie.

Définition (fonction). Soient E et F deux ensembles. Une *fonction* f de E dans F associe à **chaque** élément x de E un **unique** élément $f(x)$ de F. On note

$$f : E \longrightarrow F, \qquad x \longmapsto f(x).$$



$$x \in E \quad \Longrightarrow \quad f(x) \in F$$

— E est l'**ensemble de départ**. Il contient toutes les entrées auxquelles la fonction peut être appliquée. Dans le contexte des fonctions numériques, on parle aussi d'*ensemble de définition*.

— F est l'**ensemble d'arrivée**. Il indique la nature des sorties possibles. Toutes les valeurs de F ne sont pas nécessairement atteintes.

— Pour $x \in E$, la valeur $f(x) \in F$ est l'**image** de x par f. Inversement, si $f(x) = y$, alors x est un **antécédent** de y. Une valeur de F peut n'avoir aucun antécédent, en avoir un seul ou en avoir plusieurs.

— L'ensemble des valeurs effectivement obtenues est l'**image de la fonction**, notée

$$f(E) = \{f(x) \mid x \in E\} \subseteq F.$$

Il ne faut donc pas confondre l'ensemble d'arrivée F avec l'ensemble image $f(E)$.

La notion de fonction est toutefois beaucoup plus générale : une entrée peut être un vecteur, une date, une personne, une image ou tout autre objet, et la sortie peut elle aussi appartenir à un ensemble quelconque.

Dans ce cours, on se concentre principalement sur les **fonctions à valeurs réelles**, c'est-à-dire les fonctions dont les entrées sont des nombres réels. Elles s'écrivent typiquement

$$f : D \longrightarrow \mathbb{R},$$

L'ensemble de départ D

La fonction constitue enfin un premier pas vers la **modélisation d'un phénomène réel**. On choisit une grandeur d'entrée jugée pertinente, une grandeur de sortie que l'on souhaite expliquer, puis une règle mathématique reliant les deux. Par exemple, on peut associer à un instant la température observée, à un prix la quantité demandée, ou à une quantité produite son coût total. La fonction est une simplification du réel : elle permet d'en isoler un mécanisme, de le représenter et d'en étudier les conséquences.

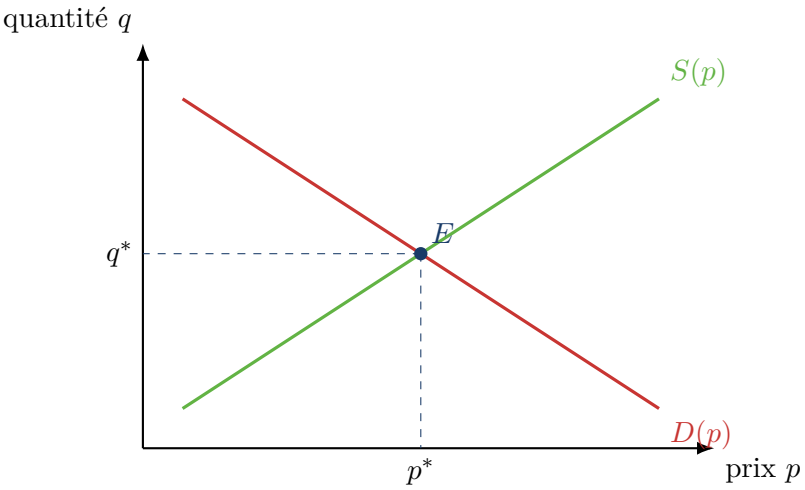
1.2 Graphe d'une fonction

On définit souvent une fonction par une formule, comme $f(x) = x^2$, mais il est souvent plus parlant de la représenter graphiquement.

Définition (graphe). Le *graphe*, ou *courbe représentative*, d'une fonction $f\colon D \to \mathbb{R}$ est l'ensemble des points du plan de coordonnées $(x, f(x))$, pour $x \in D$. On le note $\mathcal{C}_f$.

Sur un graphique, l'axe horizontal est l'axe des *abscisses*, qui porte les entrées x, et l'axe vertical celui des *ordonnées*, qui porte les valeurs $f(x)$. On fera attention à ne pas confondre le *graphe* d'une fonction, qui est une représentation visuelle, et la *fonction* elle-même, qui est un objet mathématique abstrait.

L'offre et la demande en économie. Pour illustrer ces notions, on considère l'exemple le plus simple issu de l'économie : la fonction d'offre S et la fonction de demande D. La fonction d'offre S représente la quantité de biens qu'un producteur est prêt à vendre à un prix donné, tandis que la fonction de demande D représente la quantité de biens qu'un consommateur est prêt à acheter à un prix donné. Le point d'intersection des deux courbes correspond au prix d'équilibre et à la quantité échangée sur le marché.



Remarque. Les économistes adoptent traditionnellement la convention inverse, héritée d'Alfred Marshall : le prix est porté sur l'axe vertical et la quantité sur l'axe horizontal. Ils tracent donc en réalité les courbes des fonctions réciproques, $q \mapsto p$, appelées offre et demande *inverses*. Le point d'équilibre est le même ; seule la lecture du graphique change.

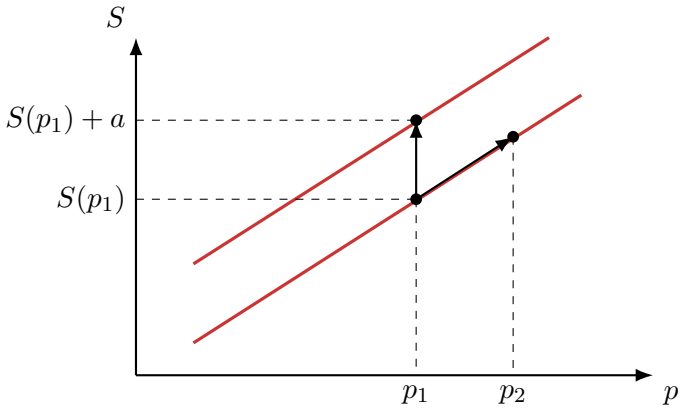
Le **prix d'équilibre** p^* est le prix pour lequel les quantités offerte et demandée sont égales :

$$S(p^*) = D(p^*) = q^*.$$

La valeur commune q^* est la **quantité d'équilibre**. Si le prix est inférieur à p^*, la demande excède l'offre. S'il est supérieur à p^*, l'offre excède la demande. Dans ce modèle simple, ces déséquilibres créent une pression qui ramène le marché vers le point d'équilibre E. On appelle cette hypothèse la **loi de l'offre et de la demande**.

Cet exemple nous permet d'aborder pour la première fois la notion de **modèle**. Personne ne prétend que la fonction d'offre ou la fonction de demande est exactement représentée par une formule mathématique simple. Cependant ces modèles capturent des propriétés essentielles de la réalité : l'offre est croissante avec le prix, la demande est décroissante avec le prix. Ils permettent surtout de raisonner sur les conséquences d'une variation de prix ou d'une variation de la demande ou de l'offre : c'est le caractère **prédictif** du modèle. On peut alors vérifier si le modèle est correct en comparant les prédictions avec les observations réelles.

Déplacement d'une courbe. On considère une fonction d'offre S dépendant du prix p.



Il faut distinguer deux mécanismes.

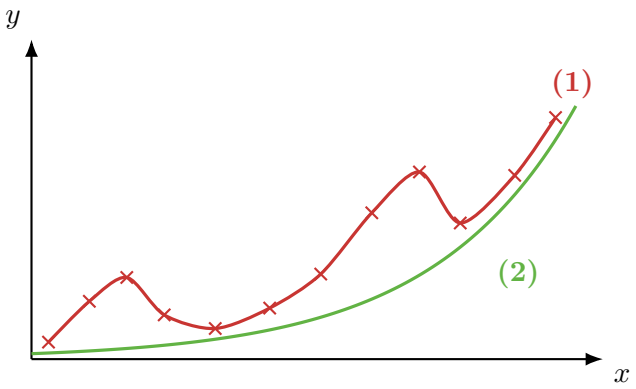
— **Déplacement de la courbe :** $S \mapsto S + a$. À prix fixé, toute la courbe est translatée. En économie, cela peut venir d'une variation du coût de production, de la technologie, d'une taxe ou du prix des matières premières.

— **Déplacement sur la courbe :** $S(p_1) \mapsto S(p_2)$. La fonction ne change pas ; seule la valeur du prix varie. Sur une courbe d'offre croissante, une hausse du prix augmente la quantité offerte.

À travailler. Refaire le même raisonnement pour une courbe de demande, généralement décroissante, puis traiter l'exercice correspondant du TD 1.

1.3 | Fonctions de référence

Une fonction de référence est un modèle simple dont on connaît la courbe et les propriétés : domaine, signe, variations, convexité et limites. Elle sert ensuite de point de comparaison pour étudier des fonctions plus complexes.



La courbe (1) représente des observations réelles, irrégulières. La courbe (2) est celle d'une fonction de référence : sa forme simple aide à construire un modèle et à en interpréter la tendance générale. Elle ne passe pas exactement par les observations (1), mais elle en donne une bonne approximation et rend compte de leur tendance, ici haussière.

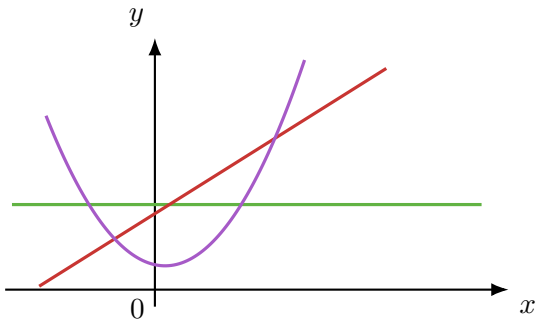
Fonctions polynomiales.

Définition. Une fonction polynomiale est une fonction $p\colon \mathbb{R} \to \mathbb{R}$ pour laquelle il existe $n \in \mathbb{N}$ et des coefficients réels $a_0, \dots, a_n$ tels que

$$p(x) = \sum_{k=0}^{n} a_k x^k = a_0 + a_1 x + \cdots + a_n x^n.$$

Si $a_n \neq 0$, l'entier n est le *degré* de p.

Les degrés 0, 1 et 2 donnent respectivement les fonctions constantes, affines et quadratiques.



Définition. Un réel a est une *racine* de p si $p(a) = 0$.

Lorsqu'on connaît les racines $a_1, \dots, a_m$, on cherche à écrire le polynôme sous forme factorisée :

$$p(x) = A \prod_{k=1}^{m} (x - a_k),$$

en tenant compte des éventuelles multiplicités. Cette écriture permet de lire immédiatement les zéros du polynôme et facilite l'étude de son signe.

Remarque. Tout polynôme non constant se factorise complètement sur $\mathbb{C}$ (théorème fondamental de l'algèbre). Sur $\mathbb{R}$, ce n'est pas toujours possible en facteurs du premier degré : par exemple, $x^2 + 1$ n'a aucune racine réelle.

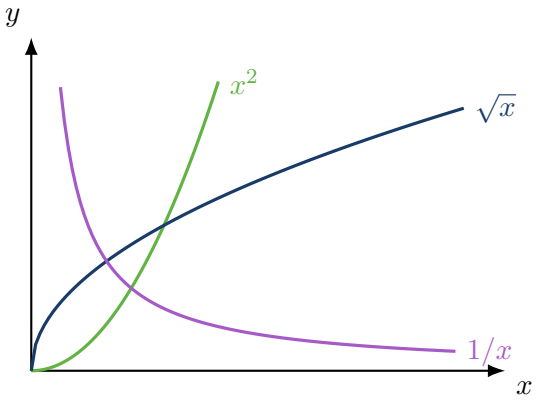
Fonctions puissances.

Définition. Pour $\alpha \in \mathbb{R}$, la fonction puissance d'exposant α est définie sur $\mathbb{R}_+^* =]0, +\infty[$ par $x \mapsto x^\alpha$.

Le domaine $\mathbb{R}_+^*$ convient à tous les exposants réels : on exclut 0 pour autoriser les exposants négatifs, et les nombres négatifs parce qu'une puissance réelle telle que $(-1)^{1/2}$ n'est pas réelle.

Pour $x > 0$ et $\alpha, \beta \in \mathbb{R}$,

$$x^{\alpha+\beta} = x^\alpha x^\beta, \qquad (x^\alpha)^\beta = x^{\alpha\beta}, \qquad x^{-\alpha} = \frac{1}{x^\alpha}.$$



La fonction $x \mapsto x^2$ est convexe sur $\mathbb{R}_+$, alors que $x \mapsto \sqrt{x}$ est concave. La fonction $x \mapsto 1/x$ est décroissante et convexe sur $\mathbb{R}_+^*$.

Fonctions exponentielle et logarithme.

Définition (exponentielle). La fonction exponentielle $\exp\colon \mathbb{R} \to \mathbb{R}_+^*$ est l'unique fonction y vérifiant

$$y' = y, \qquad y(0) = 1.$$

On écrit aussi $\exp(x) = \mathrm{e}^x$, où $\mathrm{e} = \exp(1)$.

Cette définition utilise la notion de dérivée, rappelée à la section 1.5. Intuitivement, la condition $y' = y$ signifie que la fonction croît à une vitesse égale à sa propre valeur : plus elle est grande, plus elle croît vite.

Proposition. Pour tous $x, y \in \mathbb{R}$,

$$\exp(x+y) = \exp(x)\exp(y).$$

Cette propriété fondamentale traduit une **croissance proportionnelle** : sur des durées égales, une grandeur exponentielle est toujours multipliée par le même facteur, quel que soit le point de départ.

Exemple (croissance d'une population). Une population de 10 millions d'habitants croît continûment au taux de 2 % par an. Sa taille, en millions, après t années est

$$P(t) = 10\,\mathrm{e}^{0{,}02\,t}.$$

D'après la proposition, pour tout $t \geq 0$,

$$P(t+35) = 10\,\mathrm{e}^{0{,}02\,t+0{,}7} = P(t)\,\mathrm{e}^{0{,}7} \simeq 2{,}01\,P(t).$$

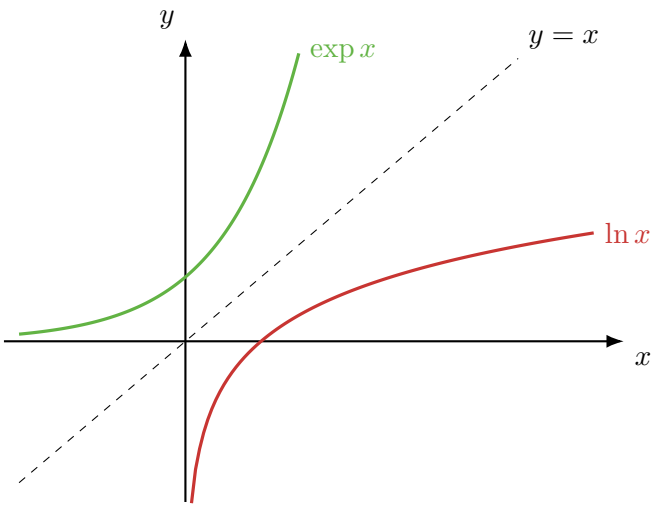
La population double donc à peu près tous les 35 ans, quelle que soit la date de départ : 10 millions aujourd'hui, environ 20 millions dans 35 ans et 40 millions dans 70 ans.

Définition (logarithme népérien). La fonction logarithme népérien $\ln\colon \mathbb{R}_+^* \to \mathbb{R}$ est la fonction réciproque de l'exponentielle :

$$\ln(\mathrm{e}^x) = x \quad (x \in \mathbb{R}), \qquad \mathrm{e}^{\ln x} = x \quad (x > 0).$$

On en déduit, pour $x, y > 0$,

$$\ln(xy) = \ln x + \ln y, \qquad \ln\left(\frac{x}{y}\right) = \ln x - \ln y, \qquad \ln(x^\alpha) = \alpha \ln x.$$



Les deux courbes sont symétriques par rapport à la droite $y = x$. L'exponentielle transforme une addition en multiplication ; le logarithme effectue l'opération inverse.

1.4 | Limites

Idée intuitive et définition. Écrire $\lim_{x\to a} f(x) = \ell$ signifie que les valeurs de $f(x)$ deviennent arbitrairement proches de ℓ lorsque x devient suffisamment proche de a, sans exiger que $x = a$ ni que $f(a) = \ell$.

Définition (limite en un point). Soit $f : D \to \mathbb{R}$. On dit que f admet la limite $\ell \in \mathbb{R}$ au point a si

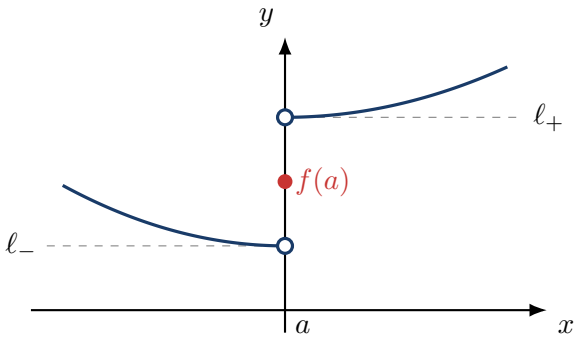
$$\forall \varepsilon > 0,\ \exists \delta > 0,\ \forall x \in D,\quad 0 < |x - a| < \delta \Longrightarrow |f(x) - \ell| < \varepsilon.$$

Autrement dit : pour toute précision $\varepsilon > 0$, aussi petite soit-elle, il existe une distance $\delta > 0$ telle que, pour tout $x \in D$ distinct de a, si x est à moins de δ de a, alors $f(x)$ est à moins de ε de ℓ.

Limites à gauche et à droite. La limite à gauche utilise seulement les valeurs $x < a$ et se note $\lim_{x\to a^-} f(x)$. La limite à droite utilise seulement les valeurs $x > a$ et se note $\lim_{x\to a^+} f(x)$.

Proposition (existence de la limite). La limite finie $\lim_{x\to a} f(x)$ existe si et seulement si les deux limites latérales existent et sont égales.

Ainsi, une fonction qui approche deux hauteurs différentes de part et d'autre de a n'admet pas de limite en a, même si la valeur $f(a)$ est définie.



Ici, $\lim\limits_{x\to a^-} f(x) = \ell_-$ et $\lim\limits_{x\to a^+} f(x) = \ell_+$, avec $\ell_- \neq \ell_+$.

Limites à l'infini et limites infinies.

Définition (limites à l'infini et limites infinies).

— $\lim\limits_{x\to+\infty} f(x) = \ell$ signifie que

$$\forall \varepsilon > 0,\ \exists R > 0,\ \forall x > R,\quad |f(x) - \ell| < \varepsilon.$$

— $\lim\limits_{x\to a} f(x) = +\infty$ signifie que

$$\forall M > 0,\ \exists \delta > 0,\quad 0 < |x - a| < \delta \Longrightarrow f(x) > M.$$

— $\lim\limits_{x\to+\infty} f(x) = +\infty$ signifie que

$$\forall M > 0,\ \exists R > 0,\ \forall x > R,\quad f(x) > M.$$

Les définitions avec $-\infty$ s'obtiennent en remplaçant les inégalités de façon appropriée.

Opérations sur les limites.

Proposition. Supposons que $f(x) \to \ell_1$ et $g(x) \to \ell_2$ lorsque $x \to a$. Alors

$$\begin{aligned} f(x) + g(x) &\longrightarrow \ell_1 + \ell_2, \\ f(x)g(x) &\longrightarrow \ell_1 \ell_2, \\ \frac{f(x)}{g(x)} &\longrightarrow \frac{\ell_1}{\ell_2} \quad \text{si } \ell_2 \neq 0. \end{aligned}$$

Pour la composition, si $f(x) \to b$ lorsque $x \to a$ et si $g(y) \to \ell$ lorsque $y \to b$, alors, sous les hypothèses usuelles de domaine, $g(f(x)) \to \ell$.

Formes indéterminées. Les expressions

$$+\infty - \infty, \qquad 0 \times \infty, \qquad \frac{0}{0}, \qquad \frac{\infty}{\infty}$$

ne permettent pas de conclure directement. Il faut transformer l'expression : factoriser, mettre au même dénominateur, simplifier ou utiliser une croissance comparée.

Croissances comparées.

Proposition (croissances comparées). Pour $a, b > 0$,

$$\lim_{x \to +\infty} \frac{x^a}{(\ln x)^b} = +\infty, \qquad \lim_{x \to 0^+} x^a |\ln x|^b = 0,$$

et

$$\lim_{x \to +\infty} \frac{x^a}{\mathrm{e}^{bx}} = 0, \qquad \lim_{x \to -\infty} |x|^a \mathrm{e}^{bx} = 0.$$

Ces résultats résument l'ordre de croissance : à $+\infty$, l'exponentielle domine toute puissance, et toute puissance positive domine le logarithme.

1.5 | Dérivation

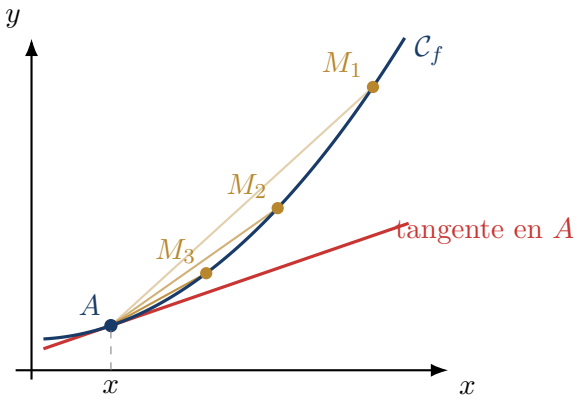
Définition et interprétation. La dérivée mesure un taux d'accroissement instantané. En physique, elle peut représenter une vitesse ; en économie, un coût marginal ou une recette marginale.

Définition. Une fonction $f \colon D \to \mathbb{R}$ est dérivable en $x \in D$ si la limite

$$\lim_{h \to 0} \frac{f(x+h) - f(x)}{h}$$

existe et est finie. Cette limite est notée $f'(x)$.

Géométriquement, $f'(x)$ est la pente de la tangente à la courbe au point d'abscisse x.



Lorsque le point M se rapproche de A, la pente de la corde (AM) tend vers celle de la tangente en A. Lorsque h est petit,

$$f(x+h) \simeq f(x) + hf'(x).$$

Cette relation est l'approximation affine locale de f au voisinage de x.

Interprétation. Si $C(q)$ est le coût total associé à la production de q unités, alors $C'(q)$ est le coût marginal. Pour une petite variation h de la production, $C(q+h) - C(q) \simeq hC'(q)$.

Dérivées usuelles.

$f(x)$	$f'(x)$
x^α	$\alpha x^{\alpha-1}$
e^x	e^x
$\ln x$	$1/x$
$\cos x$	$-\sin x$
$\sin x$	$\cos x$

Pour la fonction puissance, la formule comprend notamment les cas $1/x = x^{-1}$, $\sqrt{x} = x^{1/2}$ et x^2 sur leurs domaines respectifs.

Règles de calcul.

Proposition. Si f et g sont dérivables en x, alors

$$(fg)'(x) = f'(x)g(x) + f(x)g'(x),$$

et, si $g(x) \neq 0$,

$$\left(\frac{f}{g}\right)'(x) = \frac{f'(x)g(x) - f(x)g'(x)}{g(x)^2}.$$

Si f est dérivable en x et g dérivable en $f(x)$, la *règle de la chaîne* donne $(g \circ f)'(x) = g'(f(x))f'(x)$.

Exemples.

$$\frac{\mathrm{d}}{\mathrm{d}x}\left(x^2\mathrm{e}^x\right) = 2x\mathrm{e}^x + x^2\mathrm{e}^x = \mathrm{e}^x(2x + x^2),$$

et

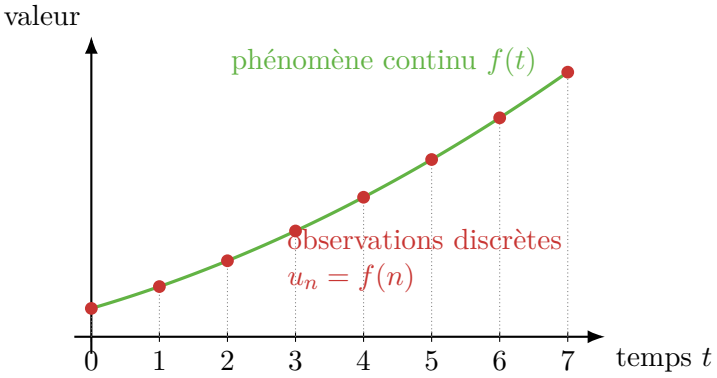
$$\frac{\mathrm{d}}{\mathrm{d}x}(x^2+1)^5 = 5(x^2+1)^4 \times 2x = 10x(x^2+1)^4.$$

À travailler. Exercices 1 à 3 du TD 1, puis les exercices d'application sur les limites et la dérivation.

2 Suites

2.1 Généralités

Dans les données réelles, les observations sont souvent discrètes : une température relevée chaque jour, un prix enregistré chaque mois ou le nombre d'utilisateurs à chaque période. Une suite est l'outil naturel pour modéliser ce type de phénomène. Souvent, le phénomène lui-même évolue de façon continue, mais il n'est observé qu'à des instants discrets : la suite regroupe alors ces relevés.



Définition. Une suite réelle est une liste ordonnée de nombres réels $u_0, u_1, u_2, \ldots, u_n, \ldots$. Le nombre u_n est le *terme de rang* n, et la suite se note $(u_n)_{n\in\mathbb{N}}$.

Une suite peut être vue comme une fonction dont la variable est un indice entier. Cette dualité donne les correspondances suivantes :

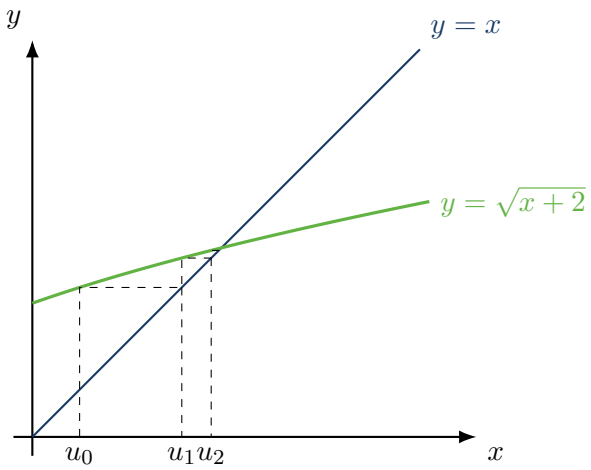
Fonction $f : \mathbb{R} \to \mathbb{R}$	Suite $(u_n)_{n\in\mathbb{N}}$
variable $x \in \mathbb{R}$	indice $n \in \mathbb{N}$
image $f(x)$	terme u_n
$x \to +\infty$	$n \to +\infty$
f croissante	$u_{n+1} - u_n \geq 0$

2.2 Modes de définition

Une suite peut être définie de deux façons principales.

1. **Forme explicite :** $u_n = f(n)$. On peut calculer directement n'importe quel terme. Exemple : $u_n = 1/(n+2)$ pour $n \geq 0$.
2. **Définition par récurrence :** on donne un terme initial et une relation permettant de calculer le suivant :
$$u_{n+1} = g(u_n), \qquad u_0 \text{ donné.}$$
Par exemple, $u_0 = 1$ et $u_{n+1} = \frac{1}{2}u_n^2 + 1$.

Pour représenter graphiquement une suite récurrente $u_{n+1} = g(u_n)$, on trace la courbe $y = g(x)$ et la droite $y = x$, puis on alterne des segments verticaux et horizontaux. Cette construction, dite en escalier, visualise les itérations.



Ici, les termes semblent se rapprocher de 2, qui est un point fixe de $g(x) = \sqrt{x+2}$ puisque $g(2) = 2$. Le dessin suggère une convergence, mais une preuve demande des arguments supplémentaires, par exemple la monotonie et le fait que la suite soit bornée.

2.3 | Suites arithmétiques

Définition. Une suite arithmétique de raison $r \in \mathbb{R}$ vérifie $u_{n+1} = u_n + r$.

Terme général et variations.

Proposition. Si (u_n) est arithmétique de raison r, alors pour tout $n \in \mathbb{N}$,

$$u_n = u_0 + nr.$$

La suite est croissante si $r > 0$, décroissante si $r < 0$ et constante si $r = 0$.

Démonstration. On démontre par récurrence, pour tout $n \in \mathbb{N}$, la propriété

$$P(n) : \qquad u_n = u_0 + nr.$$

Initialisation. Pour $n = 0$,

$$u_0 = u_0 + 0r,$$

donc $P(0)$ est vraie.

Hérédité. Soit $n \in \mathbb{N}$. Supposons $P(n)$ vraie, c'est-à-dire $u_n = u_0 + nr$. Alors, en utilisant la relation de récurrence,

$$u_{n+1} = u_n + r = (u_0 + nr) + r = u_0 + (n+1)r.$$

Ainsi, $P(n+1)$ est vraie. Par récurrence,

$$u_n = u_0 + nr \qquad (n \in \mathbb{N}).$$

Remarque. Cette démonstration est un modèle de raisonnement par récurrence : pour prouver une propriété $P(n)$ pour tout n, on vérifie d'abord $P(0)$ (ou $P(1)$ si la suite commence au rang 1), puis on établit l'hérédité $P(n) \Longrightarrow P(n+1)$.

Les variations s'en déduisent : $u_{n+1} - u_n = r$ est du signe de r.

Somme des premiers termes.

Proposition. Si (u_n) est arithmétique, alors pour tout $n \in \mathbb{N}$,

$$\sum_{k=0}^{n} u_k = \frac{n+1}{2}(u_0 + u_n).$$

Démonstration. Pour $S_n = \sum_{k=0}^{n} u_k$, on écrit la somme dans les deux sens :

$$S_n = u_0 + u_1 + \cdots + u_n, \qquad S_n = u_n + u_{n-1} + \cdots + u_0.$$

Chaque paire vaut $u_0 + u_n$, car $u_k + u_{n-k} = 2u_0 + nr = u_0 + u_n$. Il y a $n+1$ paires, donc

$$2S_n = (n+1)(u_0 + u_n).$$

2.4 | Suites géométriques

Définition. Une suite géométrique de raison $q \in \mathbb{R}$ vérifie $u_{n+1} = qu_n$.

Terme général.

Proposition. Si (u_n) est géométrique de raison q, alors pour tout $n \in \mathbb{N}$,

$$u_n = u_0 q^n.$$

Démonstration. On démontre par récurrence, pour tout $n \in \mathbb{N}$, la propriété

$$P(n) : \qquad u_n = u_0 q^n.$$

Initialisation. Pour $n = 0$,

$$u_0 = u_0 q^0,$$

donc $P(0)$ est vraie.

Hérédité. Soit $n \in \mathbb{N}$. Supposons $P(n)$ vraie, c'est-à-dire $u_n = u_0 q^n$. Alors, en utilisant la relation de récurrence,

$$u_{n+1} = qu_n = q(u_0 q^n) = u_0 q^{n+1}.$$

Ainsi, $P(n+1)$ est vraie. Par récurrence,

$$u_n = u_0 q^n \qquad (n \in \mathbb{N}).$$

Somme des premiers termes.

Proposition. Si (u_n) est géométrique de raison $q \neq 1$, alors pour tout $n \in \mathbb{N}$,

$$\sum_{k=0}^{n} u_k = u_0 \, \frac{1 - q^{n+1}}{1 - q}.$$

Si $q = 1$, cette somme vaut $(n+1)u_0$.

Démonstration. Si $q \neq 1$, on pose $S_n = 1 + q + \cdots + q^n$. Alors

$$(1-q)S_n = (1 + q + \cdots + q^n) - (q + q^2 + \cdots + q^{n+1}) = 1 - q^{n+1}.$$

Par conséquent, $S_n = \dfrac{1 - q^{n+1}}{1 - q}$, et il suffit de multiplier par u_0. Si $q = 1$, tous les termes valent u_0 et la somme vaut $(n+1)u_0$.

Étudier la croissance. Lorsque $u_n > 0$, on peut étudier le quotient u_{n+1}/u_n :

$$\frac{u_{n+1}}{u_n} > 1 \iff u_{n+1} > u_n.$$

Pour $u_{n+1} = 5u_n$ et $u_0 = 1$, tous les termes sont positifs et le quotient vaut $5 > 1$: la suite est donc croissante. En revanche, pour $u_{n+1} = -3u_n$ et $u_0 = 1$, les termes alternent de signe $(1, -3, 9, -27, \ldots)$. La suite n'est ni croissante ni décroissante.

Remarque. Le quotient est une méthode pratique seulement lorsque le signe des termes est maîtrisé. La méthode générale consiste à étudier $u_{n+1} - u_n$.

Exemple (intérêts composés). On place 1000 euros à un taux annuel de 3 %, les intérêts étant chaque année ajoutés au capital. Si C_n désigne le capital après n années, on a $C_{n+1} = C_n + 0{,}03\,C_n = 1{,}03\,C_n$: la suite (C_n) est géométrique de raison 1,03, donc

$$C_n = 1000 \times 1{,}03^n.$$

Après 10 ans, $C_{10} = 1000 \times 1{,}03^{10} \simeq 1343{,}92$ euros. Pour savoir quand le capital aura doublé, on résout $1{,}03^n \geq 2$, soit $n \ln(1{,}03) \geq \ln 2$:

$$n \geq \frac{\ln 2}{\ln 1{,}03} \simeq 23{,}4.$$

Le capital double donc au bout de 24 ans.

Interprétation. Avec des intérêts composés, les intérêts produisent eux-mêmes des intérêts : la croissance est **exponentielle**. Avec des intérêts simples, où seuls les 1000 euros initiaux rapportent 30 euros par an, le capital suivrait une suite arithmétique et ne doublerait qu'au bout de 34 ans.

2.5 | Suites arithmético-géométriques

Les suites arithmétiques et géométriques sont des cas particuliers d'une famille plus générale de suites récurrentes.

Définition. Une suite $(u_n)_{n\in\mathbb{N}}$ est dite *arithmético-géométrique* s'il existe deux réels a et b tels que

$$u_{n+1} = au_n + b.$$

Lorsque $b = 0$, on retrouve une suite géométrique. Lorsque $a = 1$, on retrouve une suite arithmétique.

L'objectif est de transformer une suite arithmético-géométrique en une suite géométrique, que l'on sait déjà étudier.

Méthode générale. On suppose que

$$u_{n+1} = au_n + b, \qquad a \neq 1.$$

Méthode.

① On cherche le **point fixe** ℓ de la relation de récurrence, c'est-à-dire le réel vérifiant

$$\ell = a\ell + b.$$

② On définit une nouvelle suite

$$v_n = u_n - \ell.$$

③ On montre que (v_n) est géométrique.

④ On détermine v_n, puis on revient à $u_n = v_n + \ell$.

En effet, puisque $\ell = a\ell + b$,

$$\begin{aligned} v_{n+1} &= u_{n+1} - \ell \\ &= au_n + b - \ell \\ &= au_n - a\ell \\ &= a(u_n - \ell) \\ &= av_n. \end{aligned}$$

La suite (v_n) est donc géométrique de raison a. Ainsi,

$$v_n = v_0 a^n = (u_0 - \ell)a^n,$$

d'où le résultat suivant.

Proposition. Soit (u_n) vérifiant $u_{n+1} = au_n + b$, avec $a \neq 1$, et soit ℓ le point fixe, solution de $\ell = a\ell + b$. Alors pour tout $n \in \mathbb{N}$,

$$u_n = \ell + (u_0 - \ell)a^n.$$

Exemple. On considère la suite définie par

$$u_0 = 5, \qquad u_{n+1} = \frac{1}{2}u_n + 3.$$

On cherche d'abord le point fixe ℓ :

$$\ell = \frac{1}{2}\ell + 3.$$

Ainsi,

$$\frac{1}{2}\ell = 3, \qquad \text{donc} \qquad \ell = 6.$$

On pose alors

$$v_n = u_n - 6.$$

On obtient

$$\begin{aligned} v_{n+1} &= u_{n+1} - 6 \\ &= \frac{1}{2}u_n + 3 - 6 \\ &= \frac{1}{2}u_n - 3 \\ &= \frac{1}{2}(u_n - 6) \\ &= \frac{1}{2}v_n. \end{aligned}$$

La suite (v_n) est donc géométrique de raison $\frac{1}{2}$. Comme

$$v_0 = u_0 - 6 = -1,$$

on a

$$v_n = -\left(\frac{1}{2}\right)^n.$$

Finalement,

$$u_n = 6 - \left(\frac{1}{2}\right)^n.$$

Cette expression permet notamment de prévoir le comportement de la suite : puisque $\left(\frac{1}{2}\right)^n \to 0$ lorsque $n \to +\infty$, la suite (u_n) est convergente, de limite 6.

Exemple (épargne avec versements réguliers). Une personne place son épargne à 3 % par an et verse en plus 1200 euros à la fin de chaque année. Partant d'un capital nul, son capital u_n vérifie

$$u_0 = 0, \qquad u_{n+1} = 1{,}03\, u_n + 1200.$$

Le point fixe vérifie $\ell = 1{,}03\,\ell + 1200$, soit $\ell = -40\,000$. Ce nombre négatif n'a pas d'interprétation concrète : c'est un simple intermédiaire de calcul. La proposition donne

$$u_n = -40\,000 + 40\,000 \times 1{,}03^n = 40\,000\,(1{,}03^n - 1).$$

Après 10 ans, $u_{10} \simeq 13\,756{,}66$ euros, pour 12 000 euros versés : les intérêts ont rapporté environ 1757 euros. Comme $1{,}03 > 1$, le capital tend vers $+\infty$.

Exemple (capital et dépréciation). Une économie dispose d'un stock de capital (machines, bâtiments) K_n à l'année n. Chaque année, 10 % du capital s'use et disparaît, et l'on investit 50 unités nouvelles :

$$K_{n+1} = 0{,}9\, K_n + 50, \qquad K_0 = 100.$$

Le point fixe vérifie $\ell = 0{,}9\,\ell + 50$, soit $\ell = 500$, d'où

$$K_n = 500 - 400 \times 0{,}9^n.$$

Comme $0{,}9^n \to 0$, le capital converge vers 500.

Interprétation. À long terme, le stock de capital se stabilise au niveau où l'usure annuelle, 10 % de 500, compense exactement l'investissement de 50. C'est l'idée d'**état stationnaire**, centrale dans les modèles de croissance économique.

2.6 Convergence des suites

Limite d'une suite

De la même manière que pour les fonctions, on s'intéresse au comportement des termes u_n lorsque n devient très grand.

Définition. Soit (u_n) une suite réelle et $\ell \in \mathbb{R}$. On dit que (u_n) *converge vers* ℓ lorsque les termes u_n deviennent arbitrairement proches de ℓ à partir d'un certain rang.
On note alors

$$\lim_{n\to+\infty} u_n = \ell.$$

Formellement,

$$\forall \varepsilon > 0, \quad \exists N \in \mathbb{N}, \quad \forall n \geq N, \qquad |u_n - \ell| \leq \varepsilon$$

Interprétation. Le réel ε représente la précision souhaitée. La définition signifie que, quelle que soit cette précision, tous les termes de la suite sont suffisamment proches de ℓ à partir d'un certain rang.

Une suite qui admet une limite finie est dite **convergente**. Une suite qui ne converge pas est dite **divergente**.

On peut également définir les limites infinies. Par exemple,

$$\lim_{n\to+\infty} u_n = +\infty$$

signifie que les termes de la suite finissent par dépasser n'importe quel nombre réel fixé. Plus précisément,

$$\forall M > 0, \quad \exists N \in \mathbb{N}, \quad \forall n \geq N, \qquad u_n \geq M.$$

Exemples. On a

$$\lim_{n\to+\infty} \frac{1}{n} = 0, \qquad \lim_{n\to+\infty} n^2 = +\infty, \qquad \lim_{n\to+\infty} \left(\frac{1}{2}\right)^n = 0.$$

En revanche, la suite

$$u_n = (-1)^n$$

ne possède pas de limite : ses termes alternent entre 1 et -1.

Ces exemples sont des cas particuliers du résultat suivant, qui décrit le comportement à long terme d'une suite géométrique.

Proposition (limite de q^n). Soit $q \in \mathbb{R}$.

- Si $q > 1$, alors $q^n \longrightarrow +\infty$.
- Si $q = 1$, alors $q^n = 1$ pour tout n.
- Si $-1 < q < 1$, alors $q^n \longrightarrow 0$.
- Si $q \leq -1$, la suite (q^n) n'a pas de limite.

Interprétation. Pour une suite géométrique $u_n = u_0 q^n$, tout dépend donc de la raison : avec un taux de croissance positif ($q > 1$), la grandeur explose ; avec un taux de décroissance ($0 < q < 1$), elle s'éteint. C'est ce résultat qui donne la limite des suites arithmético-géométriques lorsque $|a| < 1$.

Opérations sur les limites

Les règles de calcul sont essentiellement les mêmes que pour les fonctions.

Proposition. Soient (u_n) et (v_n) deux suites telles que

$$u_n \longrightarrow \ell_1, \qquad v_n \longrightarrow \ell_2.$$

Alors

$$u_n + v_n \longrightarrow \ell_1 + \ell_2,$$

et

$$u_n v_n \longrightarrow \ell_1 \ell_2.$$

Si de plus $\ell_2 \neq 0$, alors, à partir d'un certain rang, $v_n \neq 0$ et

$$\frac{u_n}{v_n} \longrightarrow \frac{\ell_1}{\ell_2}.$$

Exemples. On considère

$$u_n = \frac{2n+1}{n}.$$

En divisant chaque terme par n,

$$u_n = 2 + \frac{1}{n},$$

donc

$$\lim_{n \to +\infty} u_n = 2.$$

De même, si

$$u_n = 2 - \frac{1}{n}, \qquad v_n = 3 - \frac{2}{n},$$

alors

$$u_n \longrightarrow 2, \qquad v_n \longrightarrow 3.$$

D'après la proposition,

$$u_n + v_n \longrightarrow 5, \qquad u_n v_n \longrightarrow 6,$$

et, comme $3 \neq 0$,

$$\frac{u_n}{v_n} \longrightarrow \frac{2}{3}.$$

Enfin, considérons

$$w_n = \frac{3n^2 + 2}{2n^2 - 1}.$$

On divise le numérateur et le dénominateur par n^2 :

$$w_n = \frac{3 + \frac{2}{n^2}}{2 - \frac{1}{n^2}}.$$

Comme

$$\frac{1}{n^2} \longrightarrow 0,$$

on obtient

$$\lim_{n \to +\infty} w_n = \frac{3}{2}.$$

Théorème des gendarmes

Il est parfois difficile de calculer directement la limite d'une suite. On peut alors l'encadrer entre deux suites dont on connaît la limite.

Théorème (des gendarmes). Soient (u_n), (v_n) et (w_n) trois suites. On suppose qu'il existe $N \in \mathbb{N}$ tel que, pour tout $n \geq N$,

$$u_n \leq v_n \leq w_n.$$

Si

$$\lim_{n\to+\infty} u_n = \lim_{n\to+\infty} w_n = \ell,$$

alors

$$\lim_{n\to+\infty} v_n = \ell.$$

Exemple. Pour tout $n \geq 1$,

$$-1 \leq \sin n \leq 1.$$

En divisant par $n > 0$,

$$-\frac{1}{n} \leq \frac{\sin n}{n} \leq \frac{1}{n}.$$

Or

$$-\frac{1}{n} \longrightarrow 0, \qquad \frac{1}{n} \longrightarrow 0.$$

Le théorème des gendarmes donne donc

$$\lim_{n\to+\infty} \frac{\sin n}{n} = 0.$$

Monotonie et bornes

Définition. Soit (u_n) une suite réelle.

— (u_n) est *croissante* si

$$u_{n+1} \geq u_n \qquad \text{pour tout } n.$$

— (u_n) est *décroissante* si

$$u_{n+1} \leq u_n \qquad \text{pour tout } n.$$

— (u_n) est *majorée* s'il existe $M \in \mathbb{R}$ tel que

$$u_n \leq M \qquad \text{pour tout } n.$$

— (u_n) est *minorée* s'il existe $m \in \mathbb{R}$ tel que

$$u_n \geq m \qquad \text{pour tout } n.$$

Une suite à la fois majorée et minorée est dite **bornée**.

Théorème (convergence monotone). Soit (u_n) une suite réelle.

— Si (u_n) est croissante et majorée, alors elle converge.

— Si (u_n) est décroissante et minorée, alors elle converge.

Remarque. Les deux hypothèses sont importantes. Par exemple, la suite $u_n = n$ est croissante, mais elle n'est pas majorée : elle ne converge pas, puisque $u_n \longrightarrow +\infty$.

Remarque. La réciproque est fausse : une suite convergente n'est pas nécessairement monotone. Par exemple, pour $n \geq 1$, la suite

$$u_n = \frac{(-1)^n}{n}$$

converge vers 0, mais elle n'est ni croissante ni décroissante.

Ce théorème est particulièrement utile pour les suites définies par récurrence : on peut parfois montrer leur convergence sans connaître explicitement leur terme général. On peut même ne pas connaître la limite, mais seulement savoir qu'elle existe.

À travailler. TD 2 – Suites : suites arithmétiques, géométriques et arithmético-géométriques, calcul de limites, théorème des gendarmes et théorème de convergence monotone.

3 Systèmes d'équations linéaires

3.1 Introduction

Nous avons jusqu'ici principalement étudié des problèmes faisant intervenir une seule inconnue. Par exemple, on sait résoudre une équation linéaire comme

$$5x + 3 = 3x + 12.$$

On peut également rencontrer des équations faisant intervenir plusieurs inconnues. Par exemple,

$$x + y = 100.$$

Une seule équation ne suffit cependant généralement pas à déterminer simultanément x et y : il existe ici une infinité de couples solutions.

Pour déterminer plusieurs inconnues, on considère donc plusieurs équations simultanément. On obtient alors un **système d'équations**.

Définition. Une équation linéaire à n inconnues $x_1, \dots, x_n$ est une équation de la forme

$$a_1x_1 + \cdots + a_nx_n = b,$$

où $a_1, \dots, a_n$ et b sont des nombres réels.
Un *système linéaire* est un ensemble de plusieurs équations linéaires portant sur les mêmes inconnues.
Une solution du système doit satisfaire **toutes les équations simultanément**.

Par exemple,

$$\begin{cases} x + y = 100, \\ x - y = 40 \end{cases}$$

est un système de deux équations à deux inconnues.

Opérations sur les équations. Pour résoudre un système, on utilise des opérations qui ne changent pas son ensemble de solutions.

À partir d'une équation

$$A = B,$$

on peut notamment :

— multiplier les deux membres par un même nombre non nul ;

— ajouter un même nombre aux deux membres ;

— ajouter à une équation un multiple d'une autre équation.

Cette dernière opération est au cœur de la méthode d'élimination et, plus généralement, du pivot de Gauss.

3.2 Systèmes de deux équations à deux inconnues

Un système linéaire 2×2 est de la forme

$$\begin{cases} a_1x + b_1y = c_1, \\ a_2x + b_2y = c_2. \end{cases}$$

Nous allons voir deux méthodes élémentaires pour le résoudre.

Méthode par élimination

L'idée est de combiner les deux équations afin de faire disparaître l'une des deux inconnues.

Considérons le système

$$\begin{cases} 2x + 4y = 7, \\ 3x - 2y = 1. \end{cases}$$

On cherche ici à éliminer x. On multiplie la première équation par 3 et la seconde par 2 :

$$\begin{cases} 6x + 12y = 21, \\ 6x - 4y = 2. \end{cases}$$

On soustrait alors la seconde équation à la première :

$$(6x + 12y) - (6x - 4y) = 21 - 2,$$

d'où

$$16y = 19.$$

Ainsi,

$$y = \frac{19}{16}.$$

On remplace ensuite cette valeur dans l'une des équations initiales :

$$2x + 4\left(\frac{19}{16}\right) = 7.$$

Donc

$$2x + \frac{19}{4} = 7,$$

puis

$$2x = \frac{9}{4},$$

et finalement

$$x = \frac{9}{8}.$$

La solution du système est donc

$$(x, y) = \left(\frac{9}{8}, \frac{19}{16}\right).$$

Méthode. Pour résoudre un système 2×2 par élimination :

1. multiplier éventuellement les équations afin d'obtenir le même coefficient devant l'une des inconnues ;
2. additionner ou soustraire les deux équations afin d'éliminer cette inconnue ;
3. résoudre l'équation à une inconnue obtenue ;
4. remplacer cette valeur dans l'une des équations initiales.

Méthode par substitution

Cette méthode est particulièrement pratique lorsqu'une variable peut facilement être isolée.

Considérons

$$\begin{cases} x + 2y = 5, \\ 3x - y = 4. \end{cases}$$

La première équation donne immédiatement

$$x = 5 - 2y.$$

On substitue cette expression dans la deuxième équation :

$$3(5 - 2y) - y = 4.$$

Ainsi,

$$15 - 6y - y = 4,$$

donc

$$-7y = -11,$$

et

$$y = \frac{11}{7}.$$

On en déduit

$$x = 5 - 2 \times \frac{11}{7} = \frac{35 - 22}{7} = \frac{13}{7}.$$

La solution est donc

$$(x, y) = \left(\frac{13}{7}, \frac{11}{7}\right).$$

Interprétation graphique

Une équation linéaire à deux inconnues,

$$ax + by = c,$$

représente géométriquement une droite du plan.

Résoudre un système de deux équations revient donc à chercher les points appartenant simultanément aux deux droites, c'est-à-dire leurs points d'intersection.

Il y a trois situations possibles.

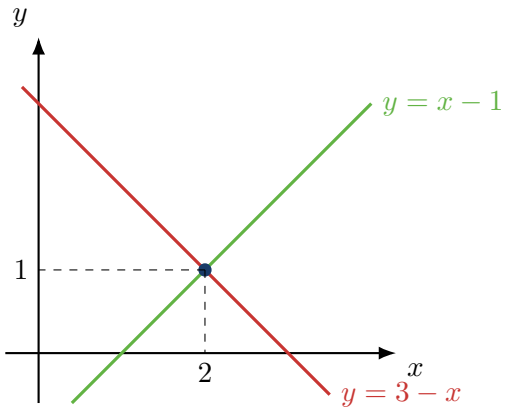
Cas 1 : une solution unique. Considérons

$$\begin{cases} x + y = 3, \\ x - y = 1. \end{cases}$$

On peut écrire

$$y = 3 - x, \qquad y = x - 1.$$

Les deux droites se coupent en un unique point.



Le système possède donc une unique solution :

$$(x, y) = (2, 1).$$

Cas 2 : aucune solution. Si les deux droites sont parallèles et distinctes, elles ne se rencontrent jamais. Le système ne possède donc aucune solution.

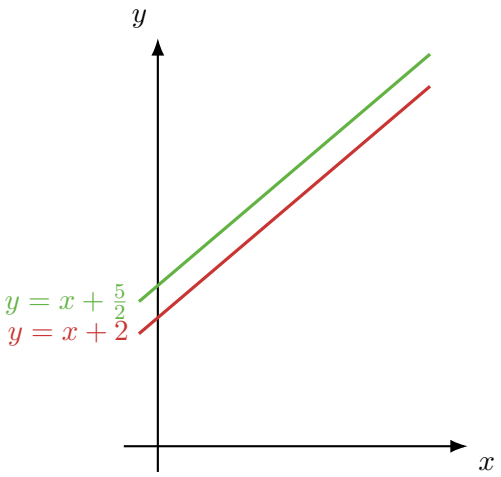
Par exemple,

$$\begin{cases} -x + y = 2, \\ -2x + 2y = 5. \end{cases}$$

Les deux équations correspondent aux droites

$$y = x + 2, \qquad y = x + \frac{5}{2},$$

qui ont la même pente mais ne sont pas confondues.

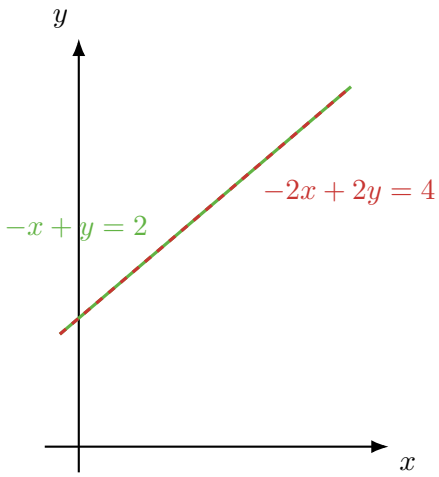


Cas 3 : une infinité de solutions. Si les deux équations décrivent exactement la même droite, chaque point de cette droite est solution du système.

Par exemple,

$$\begin{cases} -x + y = 2, \\ -2x + 2y = 4. \end{cases}$$

La seconde équation est simplement le double de la première. Le système possède donc une infinité de solutions.



Les deux tracés se superposent : tous les points de cette droite sont solutions du système.

À retenir. Un système linéaire 2×2 peut avoir :

— une unique solution ;

— aucune solution ;

— une infinité de solutions.

3.3 Systèmes à plusieurs inconnues : pivot de Gauss

Les méthodes précédentes peuvent être utilisées pour trois inconnues ou davantage, mais les calculs deviennent rapidement lourds.

La **méthode du pivot de Gauss** systématise l'élimination. Elle s'applique à un système de taille quelconque.

Considérons par exemple

$$\begin{cases} x + y + z = 6, \\ 2x - y + z = 3, \\ x + 2y - z = 2. \end{cases}$$

Remarque. Rappel des opérations disponibles sur les lignes :

— échanger deux lignes :

$$L_i \leftrightarrow L_j;$$

— multiplier une ligne par un nombre $\lambda \neq 0$:

$$L_i \leftarrow \lambda L_i;$$

— ajouter à une ligne un multiple d'une autre :

$$L_i \leftarrow L_i + \lambda L_j.$$

Ces opérations transforment le système en un système équivalent, c'est-à-dire ayant exactement les mêmes solutions.

Méthode. On applique ensuite les étapes suivantes.

① **Écriture sous forme de matrice augmentée**

On ne conserve que les coefficients des inconnues et les seconds membres :

$$\left(\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 2 & -1 & 1 & 3 \\ 1 & 2 & -1 & 2 \end{array}\right).$$

Chaque ligne représente une équation et chaque colonne correspond à une inconnue. La dernière colonne contient les seconds membres.

Cette écriture permet de se concentrer uniquement sur les opérations nécessaires à l'élimination des inconnues.

② **Première élimination**

Le premier coefficient non nul de la première colonne est utilisé comme **pivot**. Ici, le pivot est le coefficient 1 de la première ligne.

On cherche à faire apparaître des zéros sous ce pivot.

On effectue

$$L_2 \leftarrow L_2 - 2L_1, \qquad L_3 \leftarrow L_3 - L_1.$$

On obtient

$$\left(\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 0 & -3 & -1 & -9 \\ 0 & 1 & -2 & -4 \end{array}\right).$$

③ **Deuxième élimination**

On choisit maintenant un pivot dans la deuxième colonne. On peut garder -3 comme pivot et éliminer le coefficient situé en dessous.

Pour éviter les fractions, on effectue

$$L_3 \leftarrow 3L_3 + L_2.$$

Cela donne

$$\left(\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 0 & -3 & -1 & -9 \\ 0 & 0 & -7 & -21 \end{array}\right).$$

Le système est désormais **triangulaire** :

$$\begin{cases} x + y + z = 6, \\ -3y - z = -9, \\ -7z = -21. \end{cases}$$

④ **Remontée**

Il suffit maintenant de résoudre les équations en partant de la dernière.

La troisième équation donne

$$-7z = -21,$$

donc

$$z = 3.$$

La deuxième équation devient

$$-3y - 3 = -9,$$

donc

$$-3y = -6,$$

et

$$y = 2.$$

Enfin, la première équation donne

$$x + 2 + 3 = 6,$$

donc

$$x = 1.$$

Ainsi,

$$(x, y, z) = (1, 2, 3).$$

Méthode (pivot de Gauss). Pour résoudre un système linéaire :

1. écrire le système sous forme de matrice augmentée ;
2. choisir un pivot non nul dans la première colonne ;
3. effectuer des opérations sur les lignes afin d'obtenir des zéros sous le pivot ;
4. recommencer sur la colonne suivante et les lignes restantes ;
5. poursuivre jusqu'à obtenir un système triangulaire ;
6. résoudre le système par remontée, en commençant par la dernière équation.

Remarque. Si le coefficient que l'on souhaite utiliser comme pivot est nul, on peut simplement échanger deux lignes afin de placer un coefficient non nul à sa place.

Pourquoi cette méthode est-elle importante ? Pour un système 2×2, l'élimination ou la substitution sont souvent plus rapides. L'intérêt du pivot de Gauss apparaît surtout lorsque le nombre d'inconnues augmente : il fournit une méthode systématique qui peut être utilisée de la même manière pour un système 3×3, 4×4, ou plus généralement pour un système de n équations à n inconnues.

Il constitue également le point de départ de nombreuses méthodes de calcul numérique utilisées pour résoudre des systèmes de grande taille.

À travailler. Résoudre plusieurs systèmes 2×2 par élimination et substitution, interpréter graphiquement leur nombre de solutions, puis appliquer le pivot de Gauss à des systèmes 3×3.

4 Matrices

4.1 Définitions et premières opérations

Définition d'une matrice

Définition (matrice). Une *matrice* est un tableau rectangulaire de nombres. Une matrice à n lignes et m colonnes s'écrit $M = (m_{ij}) \in \mathbb{R}^{n\times m}$, où m_{ij} désigne le coefficient situé à la ligne i et à la colonne j. Lorsque $n = m$, on dit que la matrice est *carrée*.

Concrètement,

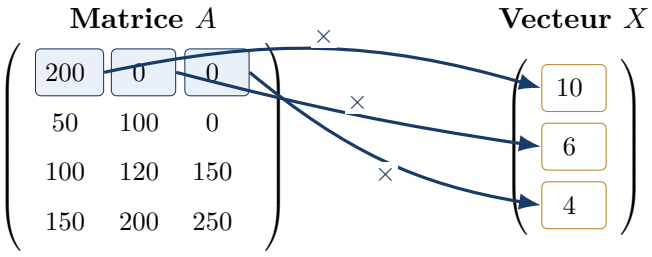
$$M = \begin{pmatrix} m_{11} & m_{12} & \cdots & m_{1m} \\ m_{21} & m_{22} & \cdots & m_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ m_{n1} & m_{n2} & \cdots & m_{nm} \end{pmatrix}.$$

La taille de M est donc $n \times m$.

Exemples.

$$A = \begin{pmatrix} 1 & 3 \\ -5 & 2 \end{pmatrix} \in \mathbb{R}^{2\times 2}, \qquad B = \begin{pmatrix} 1 & 2 \\ 0 & 0 \\ 2 & 3 \end{pmatrix} \in \mathbb{R}^{3\times 2}, \qquad C = \begin{pmatrix} 5 & 4 & -0{,}8 \\ \pi & 12 & 10^{48} \end{pmatrix} \in \mathbb{R}^{2\times 3}.$$

Une matrice permet notamment de représenter une **relation de proportionnalité entre plusieurs grandeurs**. Considérons une liste de courses pour un groupe composé de dix personnes choisissant un menu classique, six un menu végétarien et quatre un menu végane. Les colonnes du tableau suivant indiquent les quantités nécessaires par personne pour ces trois types de menus, et les lignes correspondent aux quatre familles d'aliments :



Première ligne (viande) : $200\times 10+0\times 6+0\times 4 = 2000$

Les colonnes de A correspondent, dans l'ordre, aux menus classique, végétarien et végane. Ses lignes correspondent à la viande, aux œufs, au riz et aux légumes. Le vecteur X contient le nombre de menus de chaque catégorie. Les flèches montrent comment calculer la première composante de AX : chaque coefficient de la première ligne de A est multiplié par la composante de même position dans X, puis les trois produits sont additionnés. On répète cette opération avec chacune des quatre lignes de A.

On note

$$Y = \begin{pmatrix} y_{\mathrm{v}} \\ y_{\mathrm{o}} \\ y_{\mathrm{r}} \\ y_{\mathrm{l}} \end{pmatrix}$$

le vecteur des **quantités totales à acheter**, où y_{v}, y_{o}, y_{r} et y_{l} désignent respectivement les quantités totales de viande, d'œufs, de riz et de légumes. Le produit matrice–vecteur donne

$$Y = AX = \begin{pmatrix} 200\times 10 + 0\times 6 + 0\times 4 \\ 50\times 10 + 100\times 6 + 0\times 4 \\ 100\times 10 + 120\times 6 + 150\times 4 \\ 150\times 10 + 200\times 6 + 250\times 4 \end{pmatrix} = \begin{pmatrix} 2000 \\ 1100 \\ 2320 \\ 3700 \end{pmatrix}.$$

Ainsi, si les coefficients de A sont exprimés en grammes par personne, il faut acheter 2 kg de viande, 1,1 kg d'œufs, 2,32 kg de riz et 3,7 kg de légumes. Chaque composante de Y est obtenue en multipliant la ligne correspondante de A par le vecteur X.

Produit matrice–vecteur

Définition (produit matrice–vecteur). Soient $A = (a_{ij}) \in \mathbb{R}^{n\times m}$ et $X = (x_1, \dots, x_m)^{\mathsf{T}} \in \mathbb{R}^m$. Le *produit matrice–vecteur* $AX \in \mathbb{R}^n$ est défini par

$$(AX)_i = \sum_{k=1}^{m} a_{ik} x_k.$$

Autrement dit, la composante i de AX est le produit scalaire de la ligne i de A avec le vecteur X.

Exemple.

$$\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \begin{pmatrix} 5 \\ 6 \end{pmatrix} = \begin{pmatrix} 1\times 5 + 2\times 6 \\ 3\times 5 + 4\times 6 \end{pmatrix} = \begin{pmatrix} 17 \\ 39 \end{pmatrix}.$$

Produit de deux matrices

Le produit matrice–vecteur se généralise au produit de deux matrices.

Définition (produit de deux matrices). Soient $A \in \mathbb{R}^{n\times m}$ et $B \in \mathbb{R}^{m\times \ell}$. Le *produit* $AB \in \mathbb{R}^{n\times \ell}$ est défini par

$$(AB)_{ij} = \sum_{k=1}^{m} a_{ik} b_{kj}.$$

Chaque colonne de AB est obtenue en multipliant A par la colonne correspondante de B :

$$B = \begin{pmatrix} B_1 & B_2 & \cdots & B_\ell \end{pmatrix} \quad \Longrightarrow \quad AB = \begin{pmatrix} AB_1 & AB_2 & \cdots & AB_\ell \end{pmatrix}.$$

Proposition (compatibilité des dimensions). Le produit AB est défini si et seulement si le nombre de colonnes de A est égal au nombre de lignes de B. Le résultat possède le nombre de lignes de A et le nombre de colonnes de B :

$$\underbrace{A}_{n\times m}\,\underbrace{B}_{m\times \ell} = \underbrace{AB}_{n\times \ell}.$$

Exemples.

$$\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \begin{pmatrix} 2 & 0 \\ 1 & 3 \end{pmatrix} = \begin{pmatrix} 1\times 2 + 2\times 1 & 1\times 0 + 2\times 3 \\ 3\times 2 + 4\times 1 & 3\times 0 + 4\times 3 \end{pmatrix} = \begin{pmatrix} 4 & 6 \\ 10 & 12 \end{pmatrix}.$$

Le produit d'un vecteur ligne par un vecteur colonne est un réel :

$$\begin{pmatrix} 2 & 3 \end{pmatrix} \begin{pmatrix} 4 \\ 5 \end{pmatrix} = 2 \times 4 + 3 \times 5 = 23.$$

Remarque. Le produit matriciel n'est en général pas commutatif : même lorsque AB et BA sont tous deux définis, on a le plus souvent $AB \neq BA$. Par exemple, en multipliant les deux matrices précédentes dans l'autre ordre,

$$\begin{pmatrix} 2 & 0 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} = \begin{pmatrix} 2 & 4 \\ 10 & 14 \end{pmatrix} \neq \begin{pmatrix} 4 & 6 \\ 10 & 12 \end{pmatrix}.$$

Exemple (coût des courses). Reprenons la liste de courses, en exprimant cette fois les quantités par personne en kilogrammes :

$$A = \begin{pmatrix} 0{,}2 & 0 & 0 \\ 0{,}05 & 0{,}1 & 0 \\ 0{,}1 & 0{,}12 & 0{,}15 \\ 0{,}15 & 0{,}2 & 0{,}25 \end{pmatrix}, \qquad X = \begin{pmatrix} 10 \\ 6 \\ 4 \end{pmatrix}.$$

Supposons que la viande coûte 15 euros le kilo, les œufs 6, le riz 2 et les légumes 3. On range ces prix dans un vecteur **ligne** $P = \begin{pmatrix} 15 & 6 & 2 & 3 \end{pmatrix}$. Le coût total des courses est le produit de P par le vecteur colonne $Y = AX$ des quantités à acheter :

$$PY = \begin{pmatrix} 15 & 6 & 2 & 3 \end{pmatrix} \begin{pmatrix} 2 \\ 1{,}1 \\ 2{,}32 \\ 3{,}7 \end{pmatrix} = 30 + 6{,}6 + 4{,}64 + 11{,}1 = 52{,}34 \text{ euros}.$$

On peut aussi calculer d'abord le produit PA, qui est un vecteur ligne :

$$PA = \begin{pmatrix} 3{,}95 & 1{,}44 & 1{,}05 \end{pmatrix}.$$

Ses coefficients ont un sens économique : c'est le **coût d'un menu** de chaque type, soit 3,95 euros pour un menu classique, 1,44 euro pour un menu végétarien et 1,05 euro pour un menu végane. On retrouve alors

$$(PA)X = 3{,}95 \times 10 + 1{,}44 \times 6 + 1{,}05 \times 4 = 52{,}34 \text{ euros}.$$

Remarque. L'égalité $P(AX) = (PA)X$ n'est pas un hasard : le produit matriciel est *associatif*, c'est-à-dire que $(AB)C = A(BC)$ dès que les produits sont définis. On peut donc écrire simplement PAX.

Somme et multiplication par un réel

Définition (somme, multiplication par un réel). Soient $A = (a_{ij})$ et $B = (b_{ij})$ deux matrices de $\mathbb{R}^{n \times m}$ et $\lambda \in \mathbb{R}$. La *somme* $A + B$ et le *produit* λA sont définis coefficient par coefficient :

$$(A + B)_{ij} = a_{ij} + b_{ij}, \qquad (\lambda A)_{ij} = \lambda a_{ij}.$$

Ces opérations sont simples à distinguer du produit matriciel : additionner deux matrices ou multiplier une matrice par un réel se fait coefficient par coefficient, tandis que le produit matriciel combine lignes et colonnes.

Proposition (linéarité du produit matriciel). Pour des matrices de dimensions compatibles et tout $\lambda \in \mathbb{R}$,

$$(A + B)C = AC + BC, \qquad \lambda(AB) = (\lambda A)B = A(\lambda B).$$

4.2 | Chaînes de Markov

Une **chaîne de Markov** décrit l'évolution d'un système pouvant se trouver dans un nombre fini d'états. À chaque étape, la probabilité de passer à l'état suivant dépend uniquement de l'état présent. On dit que le processus est **sans mémoire**. Cette hypothèse est un choix de modélisation : en réalité, peu de systèmes la vérifient, mais il s'agit d'une approximation très utile mathématiquement. Prenons l'exemple du prix d'une action sur un marché financier. Il est assez courant en mathématiques financière de décrire le prix $P(t)$ de l'action par un *mouvement Brownien*, qui est un processus aléatoire Markovien, c'est à dire sans mémoire. En pratique, il est facile de se convaincre que le prix est surement fortement non Markovien. En effet, deux actions peuvent avoir le même prix $P_1(t) = P_2(t) = 100$ au temps t, mais l'action 1 monte de manière continue depuis plusieurs jours, alors que l'action 2 dégringole. Un modèle Markovien ne ferait pas la différence entre ces deux situations.

Exemple (choix du mode de transport). Une population choisit chaque année entre la voiture, les transports en commun et le vélo. On suppose les transitions suivantes :

— parmi les automobilistes, 70 % gardent la voiture, 20 % passent aux transports en commun et 10 % au vélo,

— parmi les usagers des transports en commun, 10 % choisissent la voiture, 60 % restent dans les transports en commun et 30 % passent au vélo,

— parmi les cyclistes, 5 % passent à la voiture, 20 % aux transports en commun et 75 % restent à vélo.

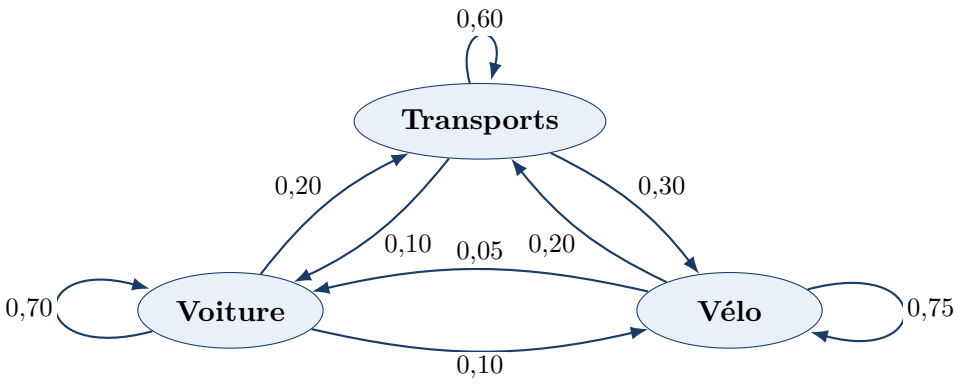
On note v_n, t_n et b_n les proportions d'usagers de la voiture, des transports en commun et du vélo à l'année n, puis

$$X_n = \begin{pmatrix} v_n \\ t_n \\ b_n \end{pmatrix}.$$

L'évolution s'écrit

$$X_{n+1} = AX_n, \qquad A = \begin{pmatrix} 0{,}70 & 0{,}10 & 0{,}05 \\ 0{,}20 & 0{,}60 & 0{,}20 \\ 0{,}10 & 0{,}30 & 0{,}75 \end{pmatrix}.$$

Le coefficient a_{ij} est la probabilité de passer de l'état j à l'état i. Les coefficients d'une même colonne ont donc pour somme 1.



En répétant la relation de récurrence, on obtient

$$X_n = A^n X_0.$$

La chaîne de Markov est ainsi l'analogue matriciel d'une suite géométrique.

État stationnaire. Si la suite (X_n) converge vers un vecteur X, alors le passage à la limite dans $X_{n+1} = AX_n$ conduit à

$$AX = X.$$

Il faut compléter cette équation par la condition $v + t + b = 1$. Pour l'exemple précédent, on obtient

$$X = \begin{pmatrix} 4/21 \\ 1/3 \\ 10/21 \end{pmatrix} \simeq \begin{pmatrix} 0{,}190 \\ 0{,}333 \\ 0{,}476 \end{pmatrix}.$$

À long terme, environ 19 % de la population utilise la voiture, 33 % les transports en commun et 48 % le vélo, indépendamment de la répartition initiale dans ce modèle.

4.3 | Matrice inverse et pivot de Gauss

Matrice identité et inverse

Définition (matrice identité). La *matrice identité* de taille n, notée I_n, est la matrice carrée dont les coefficients diagonaux valent 1 et les autres 0.

Ainsi,

$$I_n = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \cdots & 0 & 1 \end{pmatrix}.$$

Pour toute matrice $A \in \mathbb{R}^{n\times n}$,

$$AI_n = I_n A = A.$$

Définition (matrice inversible). Une matrice carrée $A \in \mathbb{R}^{n\times n}$ est dite *inversible* s'il existe une matrice A^{-1} telle que

$$AA^{-1} = A^{-1}A = I_n.$$

Cette matrice, lorsqu'elle existe, est unique et s'appelle l'*inverse* de A.

L'inverse joue pour les matrices un rôle analogue à celui de $1/x$ pour un nombre non nul. Il permet notamment de résoudre l'équation matricielle

$$AX = Y.$$

Si A est inversible, on multiplie à gauche par A^{-1} :

$$A^{-1}AX = A^{-1}Y \quad \Longrightarrow \quad X = A^{-1}Y.$$

Proposition. Si A est inversible, l'équation $AX = Y$ admet une unique solution :

$$X = A^{-1}Y.$$

Remarque. Comme le produit matriciel est non commutatif, l'ordre des facteurs est essentiel : pour isoler X dans $AX = Y$, on doit multiplier les deux membres à gauche par A^{-1}.

Exemple. Le système

$$\begin{cases} 3x + 2y = 13, \\ x - y = 1 \end{cases}$$

s'écrit

$$\underbrace{\begin{pmatrix} 3 & 2 \\ 1 & -1 \end{pmatrix}}_{A} \underbrace{\begin{pmatrix} x \\ y \end{pmatrix}}_{X} = \underbrace{\begin{pmatrix} 13 \\ 1 \end{pmatrix}}_{Y}.$$

Comme

$$A^{-1} = \frac{1}{5}\begin{pmatrix} 1 & 2 \\ 1 & -3 \end{pmatrix},$$

on trouve

$$X = A^{-1}Y = \frac{1}{5}\begin{pmatrix} 1 & 2 \\ 1 & -3 \end{pmatrix}\begin{pmatrix} 13 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 2 \end{pmatrix}.$$

Calcul de l'inverse par le pivot de Gauss

Le pivot de Gauss permet non seulement de résoudre un système linéaire, mais aussi d'inverser une matrice. Pour une matrice carrée A, on forme la matrice augmentée

$$(A \mid I_n).$$

On applique ensuite les mêmes opérations élémentaires aux deux blocs jusqu'à transformer le bloc de gauche en I_n. Si l'on obtient

$$(I_n \mid B),$$

alors $B = A^{-1}$. Si le bloc de gauche ne peut pas être réduit à l'identité, la matrice n'est pas inversible.

Exemple. Pour

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix},$$

on part de

$$\left(\begin{array}{cc|cc} 2 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 \end{array}\right).$$

On effectue successivement $L_2 \leftarrow 2L_2 - L_1$, $L_1 \leftarrow L_1 - L_2$, puis $L_1 \leftarrow \frac{1}{2}L_1$:

$$\left(\begin{array}{cc|cc} 2 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 \end{array}\right) \longrightarrow \left(\begin{array}{cc|cc} 2 & 1 & 1 & 0 \\ 0 & 1 & -1 & 2 \end{array}\right) \longrightarrow \left(\begin{array}{cc|cc} 2 & 0 & 2 & -2 \\ 0 & 1 & -1 & 2 \end{array}\right) \longrightarrow \left(\begin{array}{cc|cc} 1 & 0 & 1 & -1 \\ 0 & 1 & -1 & 2 \end{array}\right).$$

Ainsi,

$$A^{-1} = \begin{pmatrix} 1 & -1 \\ -1 & 2 \end{pmatrix}.$$

Reconnaître une matrice non inversible. Considérons

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 1 & 1 & 1 \\ 2 & 4 & 6 \end{pmatrix}.$$

La troisième ligne est le double de la première. En effectuant $L_3 \leftarrow L_3 - 2L_1$, on obtient une ligne nulle dans le bloc de gauche. Celui-ci ne pourra donc jamais devenir I_3 : la matrice A n'est pas inversible.

Proposition (critère d'inversibilité). Une matrice carrée A est inversible si et seulement si le pivot de Gauss transforme A en la matrice identité.

Formule dans le cas 2×2

Dans le cas des matrices 2×2, il est assez facile d'appliquer le pivot de Gauss à des coefficients arbitraires. On peut donc apprendre par coeur la formule suivante, qui évite de refaire le calcul dans chaque cas particulier.

Définition (déterminant). Soit

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \in \mathbb{R}^2,$$

Le *déterminant* de A est le nombre

$$\det(A) = ad - bc.$$

Proposition (inverse d'une matrice 2×2). La matrice A est inversible si et seulement si $ad - bc \neq 0$. Dans ce cas,

$$A^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}.$$

Démonstration. En posant $\Delta = ad - bc$ et en supposant d'abord $a \neq 0$, les opérations sur la matrice augmentée donnent

$$\left(\begin{array}{cc|cc} a & b & 1 & 0 \\ c & d & 0 & 1 \end{array}\right) \sim \left(\begin{array}{cc|cc} a & b & 1 & 0 \\ 0 & \Delta & -c & a \end{array}\right) \sim \left(\begin{array}{cc|cc} 1 & 0 & d/\Delta & -b/\Delta \\ 0 & 1 & -c/\Delta & a/\Delta \end{array}\right).$$

Ces opérations sont possibles exactement lorsque $\Delta \neq 0$. Si $a = 0$ et $\Delta \neq 0$, on commence par échanger les deux lignes.

Dès que la dimension est plus grande que 2, on utilise systématiquement le pivot de Gauss. Numériquement, on utiliserait la même méthode pour inverser des matrices de grande taille.

Remarque. Le fait que l'inversibilité de A ne dépend que d'un seul nombre, le déterminant, est une propriété vraie en nimporte quelle dimension, mais la formule est plus compliquée.

4.4 | Application : le modèle de Leontief

Dans une économie, les secteurs dépendent les uns des autres : pour produire de l'acier, il faut de l'électricité ; pour produire de l'électricité, il faut de l'acier, etc. L'économiste Wassily Leontief (prix Nobel 1973) a proposé de décrire ces interdépendances à l'aide de **tableaux entrées–sorties**, et de calculer la production nécessaire dans chaque secteur grâce aux matrices.

On considère une économie à deux secteurs, l'agriculture et l'industrie, et l'on note x_1 et x_2 leurs productions (en milliards d'euros). Pour produire, chaque secteur consomme une partie de la production des autres :

— pour produire 1 euro de biens agricoles, il faut 0,2 euro de biens agricoles (semences, fourrage) et 0,4 euro de biens industriels (machines, engrais) ;

— pour produire 1 euro de biens industriels, il faut 0,3 euro de biens agricoles et 0,1 euro de biens industriels.

Définition (matrice des coefficients techniques). Dans une économie à n secteurs, la *matrice des coefficients techniques* est la matrice $A = (a_{ij}) \in \mathbb{R}^{n \times n}$, où a_{ij} est la quantité de bien i nécessaire pour produire une unité de bien j.

Ici, la colonne j décrit ce que consomme le secteur j :

$$A = \begin{pmatrix} 0{,}2 & 0{,}3 \\ 0{,}4 & 0{,}1 \end{pmatrix}, \qquad X = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}.$$

Le vecteur AX représente alors la **consommation intermédiaire** : ce que les secteurs utilisent pour produire X. Ce qui reste, $X - AX$, est disponible pour la **demande finale** D (ménages, État, exportations). On cherche donc la production X telle que

$$X = AX + D, \qquad \text{c'est-à-dire} \qquad (I_2 - A)X = D.$$

Proposition. Si la matrice $I_n - A$ est inversible, la production permettant de satisfaire la demande finale D est
$$X = (I_n - A)^{-1} D.$$

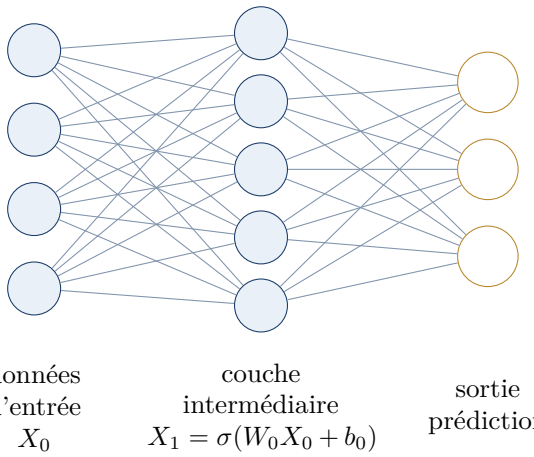
Exemple. On souhaite satisfaire une demande finale de 60 en agriculture et de 120 dans l'industrie. On a
$$I_2 - A = \begin{pmatrix} 0{,}8 & -0{,}3 \\ -0{,}4 & 0{,}9 \end{pmatrix}, \qquad \det(I_2 - A) = 0{,}8 \times 0{,}9 - 0{,}3 \times 0{,}4 = 0{,}6 \neq 0,$$
donc, d'après la formule de l'inverse d'une matrice 2×2,
$$(I_2 - A)^{-1} = \frac{1}{0{,}6} \begin{pmatrix} 0{,}9 & 0{,}3 \\ 0{,}4 & 0{,}8 \end{pmatrix} = \begin{pmatrix} 1{,}5 & 0{,}5 \\ 2/3 & 4/3 \end{pmatrix}.$$
Ainsi,
$$X = (I_2 - A)^{-1} D = \begin{pmatrix} 1{,}5 & 0{,}5 \\ 2/3 & 4/3 \end{pmatrix} \begin{pmatrix} 60 \\ 120 \end{pmatrix} = \begin{pmatrix} 150 \\ 200 \end{pmatrix}.$$
Il faut produire 150 en agriculture et 200 dans l'industrie. On vérifie que $AX = \begin{pmatrix} 90 \\ 80 \end{pmatrix}$ et que $X - AX = \begin{pmatrix} 60 \\ 120 \end{pmatrix} = D$.

Interprétation. Pour satisfaire une demande finale de $60 + 120 = 180$, l'économie doit produire au total 350 : près de la moitié de la production sert à produire. Les coefficients de $(I_2 - A)^{-1}$ mesurent ces effets en chaîne. Par exemple, le coefficient 1,5 signifie qu'une hausse de 1 de la demande finale de biens agricoles oblige l'agriculture à produire 1,5 de plus : il faut aussi produire les semences, les engrais, et les biens nécessaires pour produire ces biens, etc. On parle d'**effet multiplicateur**.

4.5 | Ouverture : matrices et réseaux de neurones

Un réseau de neurones est un modèle permettant d'apprendre une relation entre des données d'entrée et une sortie. Par exemple, disons que l'on veuille prédire si Kylian Mbappé marquera un but au prochain match du Real Madrid. On peut aggréger des données diverses (nombre de buts marqués au match précédents, minutes jouées, prochain adversaire, météo le jour du match....) et essayer de trouver, historiquement, une relation avec le nombre de buts marqués. On peut essayer avec des modèles très simples : par exemple, on prédit que Mbappé marquera s'il a marqué au match d'avant, et qu'il ne marquera pas sinon. Ce modèle suppose que la relation entre l'entrée (les statistiques de Mbappé) et la sortie (but ou non au prochain match) est très simple. Ce modèle très simple est probablement mieux que décider à pile ou face, mais on espère pouvoir faire mieux. On peut alors être tenté d'entrainer un réseau de neurone : c'est un modèle complexe qui peut apprendre des relations très sophistiquées. L'idée est que le réseau de neurone est une fonction mathématique d'une forme particulière (que l'on donne dans la suite) et qu'on ajuste les paramètres de cette fonction en utilisant les données historiques. On peut alors se rendre compte apprend des relations intuitives (lorsque Mbappé a beaucoup marqué dans les derniers matchs, il marque plus au prochain match) ou moins intuitives (Mbappé marque plus quand il pleut).

Mathématiquement, un réseau de neurones est une composition de fonctions. Une couche transforme un vecteur d'entrée X_k selon la règle
$$X_{k+1} = \sigma(W_k X_k + b_k),$$
où W_k est une matrice de coefficients, b_k un vecteur de constantes et σ une fonction non linéaire appliquée composante par composante. Les matrices W_k décrivent la manière dont les informations d'une couche sont combinées pour construire la suivante.



Pendant l'**entraînement**, on cherche les matrices W_k et les vecteurs b_k qui produisent les meilleures prédictions sur des exemples connus. Pour trouver ces paramètres idéaux, on utlise les outils de **l'optimisation mathématique**, qui est le sujet du prochain chapitre.

Un LLM (Large Language Model) comme ChatGPT ou Claude fonctionne exactement de cette manière, l'entrée étant le contexte (les mots précédents dans la phrase) et la sortie est le prochain mot prédit. Ce dernier mot est ensuite ajouté au contexte, et le LLM prédit le mot suivant.

À travailler. Vérifier les dimensions dans plusieurs produits matriciels, calculer l'évolution d'une chaîne de Markov sur quelques étapes, puis inverser des matrices 2×2 par le pivot de Gauss et par la formule du déterminant.

5 Dérivation et optimisation

Le chapitre sur les fonctions a présenté la dérivée comme un taux d'accroissement instantané. On va maintenant aller plus loin dans deux directions. D'une part, on s'intéresse à la manière dont la dérivée elle-même varie : c'est la notion de **convexité**. D'autre part, on utilise la dérivée pour trouver les valeurs qui rendent une grandeur maximale ou minimale : c'est l'**optimisation**. Ces deux questions sont au cœur du raisonnement économique : coûts croissants, satisfaction décroissante, choix d'un niveau de production optimal, etc.

5.1 Convexité, concavité

Fonctions de classe $\mathcal{C}^n$

Pour étudier la convexité, on aura besoin de dériver deux fois. On commence donc par fixer un vocabulaire permettant de décrire la régularité d'une fonction.

Définition (classe $\mathcal{C}^n$). On appelle $\mathcal{C}^0$ l'ensemble des fonctions continues. Pour $n \geq 1$, on dit que $f : D \to \mathbb{R}$ est de *classe* $\mathcal{C}^n$ si f est dérivable, de dérivée continue, et si f' est de classe $\mathcal{C}^{n-1}$.

Exemples.

— $\mathcal{C}^1$: fonctions dérivables dont la dérivée est continue ;

— $\mathcal{C}^2$: fonctions deux fois dérivables, telles que f' et f'' sont continues ;

— et ainsi de suite.

Dans ce chapitre, on s'intéressera toujours à des fonctions de classe $\mathcal{C}^2$. C'est le cas de toutes les fonctions de référence (polynômes, puissances, exponentielle, logarithme) sur leur ensemble de définition.

Qu'est-ce que la convexité ?

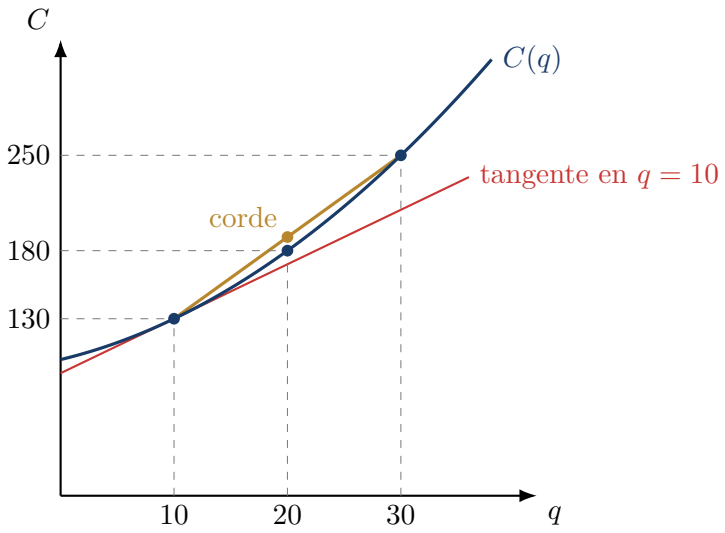
Avant de donner une définition précise, partons de l'intuition. La convexité et la concavité traduisent une idée très familière en économie : celle de **rendements ou de coûts marginaux croissants ou décroissants**.

Exemple (un coût de production). Le coût de production de q unités d'un bien est donné par

$$C(q) = 100 + 2q + 0{,}1q^2.$$

On calcule

$$C(10) = 130, \qquad C(20) = 180, \qquad C(30) = 250.$$



On constate que

$$C(20) - C(10) = 50, \qquad C(30) - C(20) = 70.$$

Dans les deux cas, on produit 10 unités de plus, mais pas au même prix : **plus on produit, plus produire une unité de plus coûte cher**. On peut traduire cette observation de deux manières.

Première lecture : la corde. L'inégalité

$$C(20) - C(10) < C(30) - C(20)$$

se réécrit $2\,C(20) < C(10) + C(30)$, c'est-à-dire

$$C\left(\frac{10+30}{2}\right) < \frac{C(10)+C(30)}{2}.$$

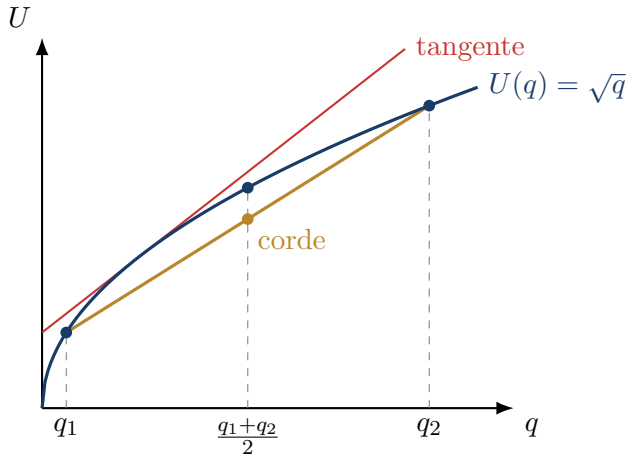
Autrement dit, produire une quantité intermédiaire coûte moins cher que faire la moyenne entre le coût d'une production faible et celui d'une production élevée. Sur le graphique, le point de la courbe d'abscisse 20 est situé *sous* le milieu de la corde joignant les points d'abscisses 10 et 30.

À retenir. Convexe $\iff$ la courbe est en dessous de ses cordes.

Seconde lecture : la tangente. La dérivée $C'(q)$ est le **coût marginal**, c'est-à-dire le coût à payer par unité supplémentaire. Ici, $C'(q) = 2 + 0{,}2q$ augmente avec q : les tangentes sont de plus en plus pentues.

À retenir. Convexe $\iff$ la pente des tangentes est croissante $\iff$ la courbe est au-dessus de ses tangentes.

Exemple (une fonction d'utilité). En économie, une **fonction d'utilité** $U(q)$ mesure la satisfaction d'un individu en fonction du nombre de biens q qu'il possède : c'est, en quelque sorte, « le bonheur comme fonction du nombre de biens ». On prend par exemple $U(q) = \sqrt{q}$.



Cette fois, tout est inversé :

— $U\left(\frac{q_1+q_2}{2}\right) \geq \frac{U(q_1)+U(q_2)}{2}$ (avec $q_1 = 1$ et $q_2 = 16$, on a $U(8{,}5) \simeq 2{,}92$ et $\frac{U(1)+U(16)}{2} = 2{,}5$) : la courbe est au-dessus de ses cordes ;

— $U'(q) = \frac{1}{2\sqrt{q}}$, appelée **utilité marginale**, décroît avec q : chaque bien supplémentaire apporte moins de satisfaction que le précédent. On parle d'**utilité marginale décroissante** ;

— la courbe est en dessous de ses tangentes.

On dit que la fonction U est **concave**.

Définition et caractérisations

Plus mathématiquement, la lecture « par les cordes » conduit à la définition suivante.

Définition (convexité, concavité). Soit $f : D \to \mathbb{R}$, où D est un intervalle. On dit que f est *convexe* si, pour tout $\lambda \in [0,1]$ et tous $x, y \in D$,

$$f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda) f(y).$$

On dit que f est *concave* si $-f$ est convexe.

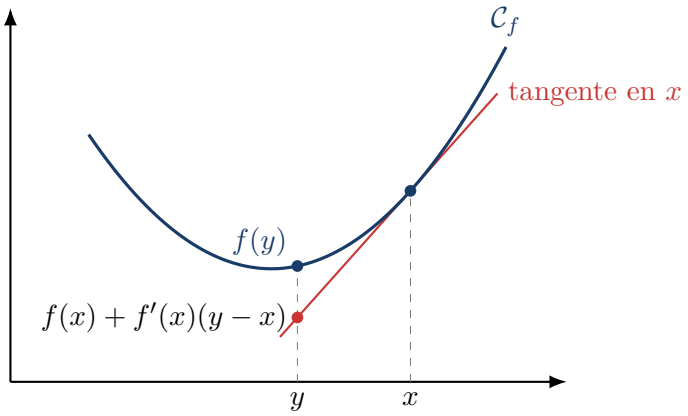
Lorsque λ parcourt $[0,1]$, le point $\lambda x + (1-\lambda)y$ parcourt l'intervalle $[x,y]$ et le membre de droite parcourt la corde joignant les points $(x, f(x))$ et $(y, f(y))$. Pour $\lambda = \frac{1}{2}$, on retrouve exactement l'inégalité obtenue sur l'exemple du coût de production.

En pratique, on utilisera plutôt l'équivalence suivante, plus simple à vérifier.

Théorème (caractérisation de la convexité). Soit $f : D \to \mathbb{R}$ de classe $\mathcal{C}^2$, où D est un intervalle. On a les équivalences suivantes :

$$f \text{ convexe} \iff f' \text{ croissante} \iff f'' \geq 0 \iff \forall x, y \in D, \quad f(y) \geq f(x) + f'(x)(y-x).$$

Remarque. Dans la dernière inégalité, la quantité $f(x) + f'(x)(y-x)$ est l'équation de la tangente en x, évaluée en y. Cette condition signifie donc que f est toujours au-dessus de toutes ses tangentes.



À retenir. Pour une fonction f de classe $\mathcal{C}^2$, la convexité peut se lire de trois façons équivalentes.
— *Définition :* $f(\lambda x+(1-\lambda)y)\leq \lambda f(x)+(1-\lambda)f(y)$.
— *Géométrique :* f est en dessous de ses cordes et au-dessus de ses tangentes.
— *Analytique :* f' est croissante, $f''\geq 0$.

Remarque. Pour la concavité, on inverse tout :

$$f \text{ concave} \iff f' \text{ décroissante} \iff f''\leq 0$$
$$\iff f \text{ au-dessus de ses cordes} \iff f \text{ en dessous de ses tangentes.}$$

Exemple. Soit $f\colon \mathbb{R}\to\mathbb{R}$, $x\mapsto x^2-2x+2$. Pour tout $x\in\mathbb{R}$,

$$f'(x)=2x-2, \qquad f''(x)=2>0.$$

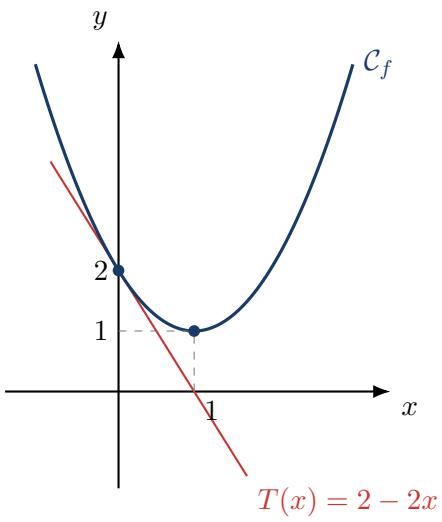
Donc f est convexe sur $\mathbb{R}$.
Regardons l'équation de la tangente en 0 :

$$T(x)=f(0)+f'(0)(x-0)=2-2x.$$

On a alors

$$f(x)-T(x)=x^2\geq 0,$$

ce qui confirme que la courbe est au-dessus de sa tangente en 0.
Pour représenter f, on l'écrit sous forme canonique : $f(x)=(x-1)^2+1$. Sa courbe est une parabole de sommet $(1,1)$.



Autres exemples.

— $f(x) = \mathrm{e}^x$ sur $\mathbb{R}$: $f''(x) = \mathrm{e}^x > 0$, donc l'exponentielle est convexe.

— $f(x) = \ln x$ sur $\mathbb{R}_+^*$: $f'(x) = \frac{1}{x}$ et $f''(x) = -\frac{1}{x^2} < 0$, donc le logarithme est concave.

Remarque. Une fonction peut être convexe sur un certain intervalle et concave sur un autre.

Points d'inflexion

Exemple. Soit $f(x) = x^3$. On a $f''(x) = 6x$. Donc f est concave sur $]-\infty, 0]$, puis convexe sur $[0, +\infty[$. Quel est le point de transition entre ces deux régimes ? C'est ce qu'on appelle un **point d'inflexion**.

Définition. Soit $f : D \to \mathbb{R}$. On dit que $a \in D$ est un *point d'inflexion* de f si f change de convexité en a.

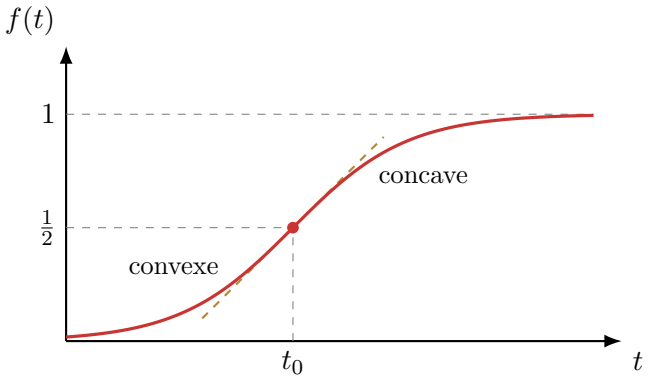
Proposition. Si $f : D \to \mathbb{R}$ est de classe $\mathcal{C}^2$, alors $a \in D$ est un point d'inflexion de f si et seulement si f'' change de signe en a.

Remarque. Il ne suffit pas que f'' s'annule en a : il faut qu'elle *change de signe*. Par exemple, pour $f(x) = x^4$, on a $f''(0) = 0$, mais $f''(x) = 12x^2 \geq 0$: la fonction est convexe sur $\mathbb{R}$ et 0 n'est pas un point d'inflexion.

Exemple (la courbe logistique). Soit $t_0 \in \mathbb{R}$ et

$$f(t) = \frac{1}{1 + \mathrm{e}^{-(t-t_0)}}.$$

On vérifie que $f'(t) = f(t)(1 - f(t)) > 0$, puis $f''(t) = f'(t)(1 - 2f(t))$. Le signe de f'' est donc celui de $1 - 2f(t)$: il est positif tant que $f(t) < \frac{1}{2}$, c'est-à-dire pour $t < t_0$, et négatif ensuite. La fonction est convexe puis concave, et t_0 est un point d'inflexion.



Interprétation. La croissance est d'abord de plus en plus rapide, puis elle ralentit après t_0 : c'est un **effet de saturation**. Ce type de courbe décrit par exemple la diffusion d'une pratique ou d'une innovation dans une population.

5.2 | Compléments de dérivation

Points critiques

On introduit ici une notion qui sera centrale lorsqu'on étudiera des fonctions de plusieurs variables.

Définition. Soit $f : D \to \mathbb{R}$ de classe $\mathcal{C}^1$. On appelle *point critique* de f tout point $a \in D$ tel que

$$f'(a) = 0.$$

Pourquoi les points critiques sont-ils importants ? Parce que c'est parmi eux que l'on trouve les maxima et minima d'une fonction.

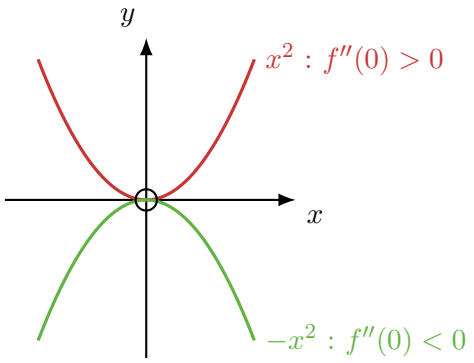
Proposition. Soit $f : D \to \mathbb{R}$ de classe $\mathcal{C}^1$. Si x_0 est un extremum local *intérieur* à D, alors $f'(x_0) = 0$.

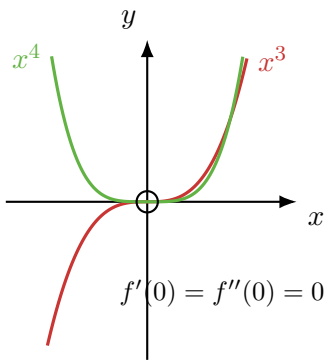
Géométriquement, au sommet d'une bosse ou au fond d'un creux, la tangente est horizontale. L'hypothèse « intérieur » est indispensable : sur $[0, 1]$, la fonction $x \mapsto x$ atteint son maximum en 1, alors que sa dérivée y vaut 1.

Remarque. La réciproque est *fausse* : un point critique n'est pas toujours un extremum.

Exemples. Les fonctions $x \mapsto x^2$ et $x \mapsto -x^2$ ont toutes deux un point critique en 0. Pour x^2, c'est un minimum, et $f''(0) > 0$; pour $-x^2$, c'est un maximum, et $f''(0) < 0$.

Quand cela échoue-t-il ? Pour $x \mapsto x^3$, on a $f'(0) = 0$ et $f''(0) = 0$, mais 0 n'est ni un minimum ni un maximum : c'est un point d'inflexion. À l'inverse, $x \mapsto x^4$ vérifie aussi $f'(0) = 0$ et $f''(0) = 0$, et 0 est bien un minimum.





Quelle est la différence entre ces situations ? C'est le signe de $f''(x_0)$.

Proposition (réciproque partielle). Soit f de classe $\mathcal{C}^2$ et $x_0 \in D$ tel que $f'(x_0) = 0$. Alors :

— si $f''(x_0) > 0$, x_0 est un minimum local ;

— si $f''(x_0) < 0$, x_0 est un maximum local.

Remarque. Si $f''(x_0) = 0$, alors on ne peut *rien* dire : voir $x \mapsto x^3$ (ni minimum ni maximum) et $x \mapsto x^4$ (minimum).

Méthode. Pour rechercher les extrema locaux d'une fonction f de classe $\mathcal{C}^2$ à l'intérieur de son domaine, on résout $f'(x) = 0$ pour obtenir les points critiques, puis on étudie le signe de f'' en chacun d'eux. Si f'' s'annule, on revient à l'étude du signe de f'.

Extremum local ou global ? Les critères précédents sont *locaux* : ils décrivent la fonction au voisinage de x_0 seulement. Un maximum local n'est pas forcément le plus grand de toutes les valeurs prises par la fonction.

Exemple. Soit $f(x) = x^3 - 3x$ sur $\mathbb{R}$. On a $f'(x) = 3x^2 - 3$, qui s'annule en -1 et en 1, et $f''(x) = 6x$. Comme $f''(-1) = -6 < 0$, le point -1 est un maximum local, avec $f(-1) = 2$. Pourtant $f(3) = 18 > 2$: ce n'est pas un maximum global.

La convexité permet de passer du local au global.

Proposition. Soit $f : I \to \mathbb{R}$ de classe $\mathcal{C}^2$ sur un intervalle I, et x_0 un point intérieur à I tel que $f'(x_0) = 0$.

— Si f est **concave** sur I, alors x_0 est un **maximum global** de f sur I.

— Si f est **convexe** sur I, alors x_0 est un **minimum global** de f sur I.

Démonstration. Si f est concave, sa courbe est en dessous de ses tangentes. Pour tout $y \in I$, on a donc, avec la tangente en x_0,

$$f(y) \leq f(x_0) + f'(x_0)(y - x_0) = f(x_0),$$

puisque $f'(x_0) = 0$. Le cas convexe est identique, l'inégalité étant renversée.

Interprétation. Pour une fonction concave, la tangente horizontale en x_0 est au-dessus de toute la courbe : le sommet atteint en x_0 est le plus haut. C'est pourquoi les économistes supposent souvent que les profits ou les utilités sont concaves : une condition du premier ordre $f'(x_0) = 0$ suffit alors à trouver l'optimum.

Exemple. Soit $f(x) = \ln x - x$ sur $\mathbb{R}_+^*$. On a $f'(x) = \frac{1}{x} - 1$, qui s'annule en $x = 1$, et $f''(x) = -\frac{1}{x^2} < 0$: f est concave sur l'intervalle $\mathbb{R}_+^*$. Le point 1 est donc un maximum global, avec $f(1) = -1$. On en déduit l'inégalité, valable pour tout $x > 0$,

$$\ln x \leq x - 1.$$

Dérivée logarithmique et élasticité

Définition (dérivée logarithmique). Soit $f : D \to \mathbb{R}_+^*$ de classe $\mathcal{C}^1$. On appelle *dérivée logarithmique* de f la fonction

$$x \longmapsto (\ln f)'(x) = \frac{f'(x)}{f(x)}.$$

L'égalité découle de la règle de la chaîne, puisque $(\ln)' = 1/x$. La dérivée logarithmique mesure des variations **relatives**, et non absolues. Par exemple, pour un coût de production C,

$$\frac{C'(q)}{C(q)} \simeq \frac{\Delta C}{\Delta q\, C(q)}.$$

C'est le coût d'une unité supplémentaire, exprimé **en pourcentage** du coût total. Avec $C(q) = 100 + 2q + 0{,}1q^2$, on a $C'(20) = 6$ et $C(20) = 180$: en $q = 20$, une unité de plus augmente le coût d'environ $6/180 \simeq 3{,}3\,\%$.

Mais si l'on veut aussi mesurer la variation de la quantité en pourcentage, c'est-à-dire l'effet de 1 % d'unités en plus ? On utilise alors l'**élasticité**.

Définition (élasticité). Soit $f : D \to \mathbb{R}_+^*$ de classe $\mathcal{C}^1$, avec $D \subseteq \mathbb{R}_+^*$. L'*élasticité* de f en x est

$$\varepsilon_f(x) = \frac{x\, f'(x)}{f(x)} = x\,(\ln f)'(x).$$

Interprétation. Lorsque x augmente de 1 %, $f(x)$ varie d'environ $\varepsilon_f(x)$ %. Dans l'exemple précédent, $\varepsilon_C(20) = \frac{20 \times 6}{180} = \frac{2}{3}$: une hausse de 1 % de la production augmente le coût d'environ 0,67 %.

Demande élastique ou inélastique. Pour une fonction de demande D, la demande diminue quand le prix augmente, donc $\varepsilon_D(p) < 0$. On compare alors $\varepsilon_D(p)$ à -1.

Définition. Soit D une fonction de demande et $p > 0$.

- Si $-1 < \varepsilon_D(p) < 0$, la demande est dite *inélastique* en p : une hausse de 1 % du prix fait baisser la demande de **moins** de 1 %.
- Si $\varepsilon_D(p) < -1$, la demande est dite *élastique* en p : une hausse de 1 % du prix fait baisser la demande de **plus** de 1 %.
- Si $\varepsilon_D(p) = -1$, on parle d'*élasticité unitaire*.

Exemple (demande inélastique). Le carburant : si le prix à la pompe augmente de 10 %, la plupart des automobilistes continuent d'aller travailler en voiture ; la consommation baisse, mais bien moins que de 10 %. Il en va de même pour le tabac, l'électricité ou les médicaments indispensables.

Exemple (demande élastique). Une marque de soda : si une marque augmente son prix de 10 %, de nombreux consommateurs se reportent sur une marque concurrente, et ses ventes chutent de bien plus de 10 %. Il en va de même pour les voyages de loisir ou une station-service particulière.

Remarque. Une demande est d'autant plus élastique que le bien a des **substituts** proches, qu'il n'est pas indispensable, qu'il pèse lourd dans le budget, et que l'on raisonne à **long terme** : à court terme, la demande de carburant est inélastique ; à long terme, on peut changer de voiture ou déménager.

Élasticité et recette. A-t-on intérêt à augmenter son prix ? La recette est $R(p) = p\,D(p)$. En dérivant le produit,

$$R'(p) = D(p) + p\,D'(p) = D(p)\left(1 + \frac{p\,D'(p)}{D(p)}\right).$$

Proposition. Pour tout $p > 0$,

$$R'(p) = D(p)\,(1 + \varepsilon_D(p)).$$

Comme $D(p) > 0$, $R'(p)$ est du signe de $1 + \varepsilon_D(p)$:

— si la demande est **inélastique**, une hausse du prix **augmente** la recette ;

— si la demande est **élastique**, une hausse du prix **diminue** la recette ;

— la recette est stationnaire là où $\varepsilon_D(p) = -1$.

Interprétation. En pourcentages, $\ln R = \ln p + \ln D$, donc une hausse de 1 % du prix fait varier la recette d'environ $(1 + \varepsilon_D)$ % : l'effet prix (+1 %) est compensé par l'effet quantité (ε_D %). Avec $\varepsilon_D = -0{,}4$, une hausse de 10 % du prix fait baisser les quantités d'environ 4 % et augmenter la recette d'environ 6 %.

Le paradoxe de King. À la fin du XVIIe siècle, le statisticien anglais Gregory King observe que le prix du blé augmente beaucoup plus que proportionnellement lorsque la récolte est mauvaise. À court terme, la quantité offerte est fixée par la récolte Q, et c'est le prix qui s'ajuste pour que toute la récolte soit vendue : $D(p) = Q$.

Prenons $D(p) = 100\,p^{-1/2}$, d'élasticité constante $-1/2$ (demande inélastique). De $100\,p^{-1/2} = Q$ on tire $p = \left(\frac{100}{Q}\right)^2$, d'où le revenu total des agriculteurs

$$R(Q) = Q\,p = \frac{10\,000}{Q},$$

fonction **décroissante** de la récolte.

Récolte	Q	Prix p	Revenu R
mauvaise	90	1,23	111,1
normale	100	1,00	100
excellente	110	0,83	90,9

Une récolte supérieure de 10 % fait baisser le revenu d'environ 9 %. Plus généralement, si $D(p) = Ap^{-\alpha}$, on obtient $p = (A/Q)^{1/\alpha}$ et $R(Q) = A^{1/\alpha}Q^{1-1/\alpha}$, qui décroît avec Q dès que $\alpha < 1$, c'est-à-dire dès que la demande est inélastique.

Interprétation. Il s'agit d'un effet **collectif**. Un agriculteur seul n'a aucune influence sur le prix : pour lui, une bonne récolte est toujours une bonne nouvelle. Ce n'est que lorsque *tous* récoltent davantage

que le revenu total baisse. Cela éclaire certaines politiques agricoles (destructions de récoltes dans les années 1930, quotas de production, prix garantis), ainsi que la stratégie de l'OPEP : la demande de pétrole étant inélastique à court terme, restreindre la production augmente la recette des pays producteurs.

À travailler. Exercices du TD 2 : convexité, tangentes et points d'inflexion, nature des points critiques, dérivée logarithmique et élasticité, puis décision de production.

5.3 | Fonctions de plusieurs variables

Jusqu'ici, toutes nos fonctions dépendaient d'une seule variable : un coût $C(q)$ dépendait de la quantité produite, une demande $D(p)$ du prix. Mais en économie, une grandeur dépend presque toujours de **plusieurs** facteurs à la fois :

— la production d'une entreprise dépend du capital K *et* du travail L ;

— la demande d'un bien dépend de son prix p *et* du revenu R des consommateurs ;

— la satisfaction d'un consommateur dépend des quantités x *et* y de deux biens qu'il consomme.

Pour décrire ces situations, on a besoin de fonctions qui prennent en entrée non plus un nombre, mais un **couple** de nombres.

Définition

On note $\mathbb{R}^2$ l'ensemble des couples (x, y) de nombres réels. Géométriquement, $\mathbb{R}^2$ s'identifie au plan muni d'un repère : le couple (x, y) est le point d'abscisse x et d'ordonnée y.

Définition. Soit D une partie de $\mathbb{R}^2$. Une *fonction de deux variables* définie sur D est une règle f qui à chaque couple $(x, y) \in D$ associe un unique nombre réel, noté $f(x, y)$. On écrit

$$f : D \longrightarrow \mathbb{R}, \qquad (x, y) \longmapsto f(x, y).$$

L'ensemble D est appelé *domaine de définition* de f.

Comme pour une variable, lorsque f est donnée par une formule, son domaine de définition est l'ensemble des couples (x, y) pour lesquels la formule a un sens.

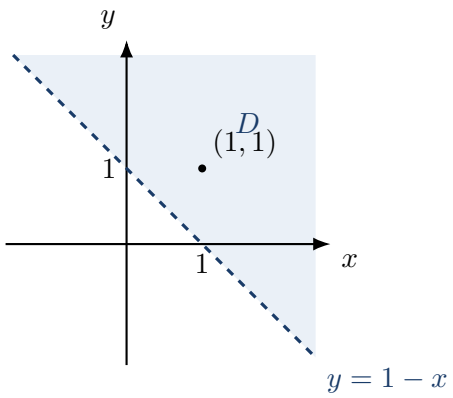
Exemples.

— $f(x, y) = x^2 + y^2$ est définie sur $\mathbb{R}^2$ tout entier. Par exemple, $f(3, 4) = 9 + 16 = 25$: c'est le carré de la distance du point $(3, 4)$ à l'origine.

— $g(x, y) = \sqrt{x - y}$ est définie lorsque $x - y \geq 0$, c'est-à-dire sur $D = \{(x, y) \in \mathbb{R}^2 : y \leq x\}$. Par exemple, $g(5, 1) = 2$, mais $g(1, 5)$ n'a pas de sens.

— $h(x, y) = \ln(x + y - 1)$ est définie lorsque $x + y - 1 > 0$, c'est-à-dire sur $D = \{(x, y) \in \mathbb{R}^2 : y > 1 - x\}$. Par exemple, $h(1, 1) = \ln 1 = 0$ et $h(2, 1) = \ln 2$.

Le domaine de h est un **demi-plan** : la partie du plan située strictement au-dessus de la droite d'équation $y = 1 - x$.



Remarque. On définit de même des fonctions de n variables $(x_1, \dots, x_n) \mapsto f(x_1, \dots, x_n)$, définies sur une partie de $\mathbb{R}^n$. Par exemple, la dépense d'un consommateur qui achète les quantités $x_1, \dots, x_n$ de n biens aux prix $p_1, \dots, p_n$ est $f(x_1, \dots, x_n) = p_1 x_1 + \cdots + p_n x_n$. Dans ce cours, on se limitera le plus souvent à deux variables.

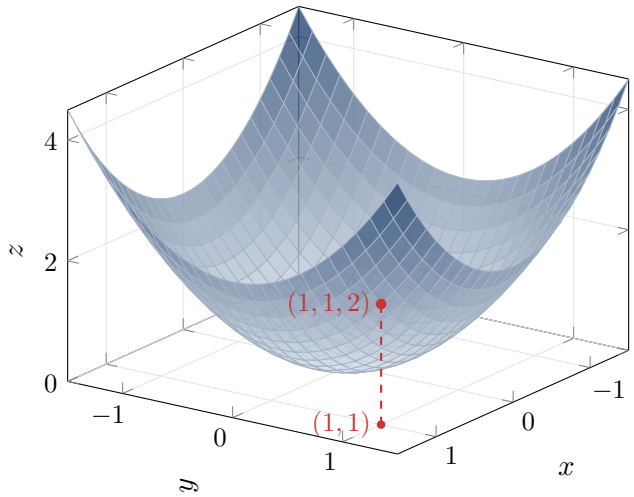
Graphe d'une fonction de deux variables. Le graphe d'une fonction d'une variable est une courbe du plan, formée des points $(x, f(x))$. Pour une fonction de deux variables, il faut trois coordonnées : deux pour l'entrée (x, y) et une pour la valeur $f(x, y)$.

Définition. Le *graphe* d'une fonction $f\colon D \to \mathbb{R}$, avec $D \subseteq \mathbb{R}^2$, est l'ensemble des points de l'espace

$$\{(x, y, z) : (x, y) \in D \text{ et } z = f(x, y)\}.$$

C'est en général une **surface** de l'espace.

Exemple. Le graphe de $f(x, y) = x^2 + y^2$ est un *paraboloïde*, représenté ci-dessous. Au-dessus de chaque point (x, y) du plan horizontal, on place un point à la hauteur $z = f(x, y)$. Par exemple, au-dessus de $(1, 1)$, la surface passe à la hauteur $f(1, 1) = 2$.



Le graphe a la forme d'un « bol » : f atteint son minimum, 0, à l'origine, et croît à mesure que l'on s'en éloigne dans n'importe quelle direction. Ce type de dessin donne une bonne intuition, mais il est difficile à tracer à la main et à lire précisément.

Exemples économiques

Fonction de production. Une entreprise utilise K unités de capital et L unités de travail, avec $K > 0$ et $L > 0$. Sa production est

$$Q(K, L) = 10\sqrt{KL}.$$

Avec $K = 4$ et $L = 9$, elle produit $Q(4, 9) = 10\sqrt{36} = 60$ unités. Si elle double ses deux facteurs, elle produit $Q(8, 18) = 10\sqrt{144} = 120$ unités.

Demande fonction du prix et du revenu. La demande d'un bien dépend de son prix $p > 0$ et du revenu $R > 0$ des ménages :

$$D(p, R) = \frac{0{,}2\,R}{p}.$$

Avec $p = 2$ et $R = 1000$, on obtient $D = 100$. Si le revenu passe à 1500 à prix inchangé, la demande passe à 150 ; si le prix double à revenu inchangé, elle tombe à 50. Une seule formule permet donc d'étudier l'effet du prix *et* celui du revenu.

Recette d'une entreprise multiproduit. Une entreprise vend x unités d'un bien au prix 3 et y unités d'un autre bien au prix 5. Sa recette est

$$R(x, y) = 3x + 5y.$$

C'est une fonction **linéaire** des quantités : $R(10, 4) = 50$.

Rendements d'échelle

Revenons à la fonction de production $Q(K, L)$ d'une entreprise. Dans l'exemple précédent, en doublant à la fois le capital et le travail, l'entreprise doublait exactement sa production : $Q(8, 18) = 120 = 2\,Q(4, 9)$. Est-ce toujours le cas ? Autrement dit : **si l'entreprise double tous ses facteurs, sa production double-t-elle ?**

Définition (rendements d'échelle). On dit que la production présente des rendements d'échelle

— *croissants* si $Q(tK, tL) > t\,Q(K, L)$ pour tout $t > 1$;

— *constants* si $Q(tK, tL) = t\,Q(K, L)$ pour tout $t > 1$;

— *décroissants* si $Q(tK, tL) < t\,Q(K, L)$ pour tout $t > 1$.

Interprétation. Avec $t = 2$: en doublant à la fois le capital et le travail, la production fait plus que doubler (rendements croissants), double exactement (rendements constants) ou fait moins que doubler (rendements décroissants).

Exemples économiques.

— **Rendements croissants** : lorsqu'il y a de gros coûts fixes ou des gains de spécialisation. Un réseau ferroviaire, un logiciel ou une centrale électrique : une fois l'infrastructure construite, servir davantage de clients coûte relativement peu.

— **Rendements constants** : lorsqu'on peut simplement dupliquer l'activité. Construire une seconde usine identique à la première, avec autant d'ouvriers, permet de produire deux fois plus.

— **Rendements décroissants** : lorsque la taille rend la coordination difficile (une très grande organisation se gère mal) ou qu'un facteur caché ne peut pas être augmenté, comme la qualité des terres agricoles disponibles.

Exemples de calcul. Soit $t > 1$.

— $Q(K, L) = 10\sqrt{KL}$: $Q(tK, tL) = 10\sqrt{t^2 KL} = 10\,t\sqrt{KL} = t\,Q(K, L)$. Les rendements sont **constants**.

— $Q(K, L) = KL$: $Q(tK, tL) = t^2 KL = t^2 Q(K, L) > t\,Q(K, L)$ car $t^2 > t$. Les rendements sont **croissants**.

— $Q(K, L) = (KL)^{1/4}$: $Q(tK, tL) = t^{1/2}(KL)^{1/4} = \sqrt{t}\,Q(K, L) < t\,Q(K, L)$ car $\sqrt{t} < t$. Les rendements sont **décroissants**.

Ces trois fonctions appartiennent à une même famille, la plus utilisée en économie pour modéliser la production.

Définition (fonction de Cobb–Douglas). Une *fonction de production de Cobb–Douglas* est une fonction de la forme

$$Q(K,L) = A\,K^{\alpha}L^{\beta}, \qquad K>0,\ L>0,$$

où $A>0$, $\alpha>0$ et $\beta>0$ sont des constantes.

Les trois exemples précédents correspondent à (A,α,β) égal à $\left(10,\frac{1}{2},\frac{1}{2}\right)$, $(1,1,1)$ et $\left(1,\frac{1}{4},\frac{1}{4}\right)$. Le coefficient A mesure le niveau technologique : à facteurs égaux, une entreprise dont le A est plus élevé produit davantage.

Remarque. Cette forme porte le nom du mathématicien Charles Cobb et de l'économiste Paul Douglas, qui l'ont ajustée en 1928 aux données de l'industrie manufacturière américaine. Ils obtenaient une production de la forme $Q \simeq 1{,}01\,K^{1/4}L^{3/4}$.

Dans tous ces exemples, multiplier les facteurs par t multiplie la production par une puissance de t. Cela motive la définition suivante.

Définition (fonction homogène). Soit $k>0$. On dit que Q est *homogène de degré k* si, pour tous $K,L>0$ et tout $t>0$,

$$Q(tK,tL) = t^{k}\,Q(K,L).$$

Les rendements d'échelle sont alors croissants si $k>1$, constants si $k=1$, et décroissants si $k<1$.

Dans le cas particulier Cobb-Douglas,

Proposition. La fonction de Cobb–Douglas $Q(K,L)=A\,K^{\alpha}L^{\beta}$ est homogène de degré $\alpha+\beta$. Ses rendements d'échelle sont donc

— croissants si $\alpha+\beta>1$;

— constants si $\alpha+\beta=1$;

— décroissants si $\alpha+\beta<1$.

Démonstration. Pour tout $t>0$,

$$Q(tK,tL) = A\,(tK)^{\alpha}(tL)^{\beta} = t^{\alpha+\beta}A\,K^{\alpha}L^{\beta} = t^{\alpha+\beta}Q(K,L).$$

Lien avec l'élasticité. Fixons (K,L) et regardons la production en fonction de l'échelle t : $g(t)=Q(tK,tL)=t^{k}\,Q(K,L)$. Son élasticité vaut

$$\varepsilon_{g}(t) = \frac{t\,g'(t)}{g(t)} = \frac{t\cdot k\,t^{k-1}Q(K,L)}{t^{k}Q(K,L)} = k.$$

Interprétation. Le degré d'homogénéité k est l'**élasticité de la production par rapport à l'échelle** : lorsque tous les facteurs augmentent de $1\,\%$, la production augmente d'environ $k\,\%$. Les rendements sont croissants lorsque cette élasticité dépasse 1.

Lien avec les coûts : économies d'échelle. Pour simplifier, supposons qu'un seul facteur, le travail, soit utilisé, avec $Q(L)=L^{k}$, et que chaque unité de travail coûte $w>0$. Pour produire q unités, il faut $L=q^{1/k}$, d'où le coût total et le coût moyen

$$C(q) = w\,q^{1/k}, \qquad \frac{C(q)}{q} = w\,q^{\frac{1}{k}-1}.$$

— Si $k > 1$ (rendements croissants), $\frac{1}{k} - 1 < 0$: le coût moyen **diminue** avec la quantité produite, et C est concave. On parle d'*économies d'échelle*.

— Si $k < 1$ (rendements décroissants), le coût moyen **augmente** et C est convexe.

Par exemple, avec $k = 2$ et $w = 10$: produire $q = 100$ coûte $C = 100$, soit 1 par unité ; produire $q = 400$ coûte $C = 200$, soit 0,5 par unité.

Interprétation. Avec des rendements croissants, les grandes entreprises produisent moins cher que les petites. C'est pourquoi certains secteurs (réseaux électriques, ferroviaires, d'eau) tendent vers un **monopole naturel** : une seule entreprise produit à un coût moyen plus faible que plusieurs concurrentes.

Fonctions partielles

Une idée simple permet de ramener l'étude d'une fonction de deux variables à celle de fonctions d'une variable, que l'on sait déjà étudier : **fixer l'une des variables**.

Définition. Soit f une fonction de deux variables et (a, b) un point de son domaine. Les *fonctions partielles* de f en (a, b) sont les fonctions d'une variable

$$x \longmapsto f(x, b) \qquad \text{et} \qquad y \longmapsto f(a, y).$$

Exemple. Pour la fonction de production $Q(K, L) = 10\sqrt{KL}$, fixons le capital à $K = 4$:

$$L \longmapsto Q(4, L) = 20\sqrt{L}.$$

C'est une fonction croissante et concave de L : à capital donné, embaucher fait augmenter la production, mais chaque unité de travail supplémentaire rapporte de moins en moins. De même, à travail fixé $L = 9$, la fonction $K \mapsto Q(K, 9) = 30\sqrt{K}$ est croissante et concave.

Interprétation. Fixer une variable, c'est raisonner « toutes choses égales par ailleurs » : on fait varier un seul facteur en gardant les autres constants. C'est exactement ce que font les économistes lorsqu'ils isolent l'effet du prix sur la demande à revenu donné. Les outils du chapitre (dérivée, convexité, élasticité) s'appliquent alors directement aux fonctions partielles : c'est l'idée des **dérivées partielles**.

Remarque. Géométriquement, fixer $y = b$ revient à couper le graphe de f par le plan vertical d'équation $y = b$: la courbe obtenue est le graphe de la fonction partielle $x \mapsto f(x, b)$. Pour $f(x, y) = x^2 + y^2$ et $b = 1$, on obtient la parabole $z = x^2 + 1$.

Dérivées partielles

Puisque les fonctions partielles sont des fonctions d'une variable, on peut les dériver. On obtient ainsi le taux de variation de f lorsqu'une seule variable bouge, l'autre restant fixe.

Définition (dérivées partielles). Soit f une fonction de deux variables et (a, b) un point intérieur à son domaine. La *dérivée partielle* de f par rapport à x en (a, b) est la dérivée en a de la fonction partielle $x \mapsto f(x, b)$, lorsqu'elle existe :

$$\frac{\partial f}{\partial x}(a, b) = \lim_{h \to 0} \frac{f(a + h, b) - f(a, b)}{h}.$$

De même, la dérivée partielle par rapport à y est

$$\frac{\partial f}{\partial y}(a, b) = \lim_{h \to 0} \frac{f(a, b + h) - f(a, b)}{h}.$$

On note aussi $\partial_x f$ et $\partial_y f$. Le symbole ∂, un « d » arrondi, rappelle qu'on ne dérive que par rapport à *une partie* des variables.

Méthode. Pour calculer $\dfrac{\partial f}{\partial x}$, on dérive l'expression de f par rapport à x en traitant y comme une constante, et inversement pour $\dfrac{\partial f}{\partial y}$. Toutes les règles de dérivation d'une variable s'appliquent.

Exemples.

— Pour $f(x,y) = x^2 y + 3y^3$:

$$\frac{\partial f}{\partial x}(x,y) = 2xy, \qquad \frac{\partial f}{\partial y}(x,y) = x^2 + 9y^2.$$

Dans le calcul de $\partial_x f$, le terme $3y^3$ est une constante, dont la dérivée est nulle.

— Pour $g(x,y) = x\,\mathrm{e}^{2y}$:

$$\frac{\partial g}{\partial x}(x,y) = \mathrm{e}^{2y}, \qquad \frac{\partial g}{\partial y}(x,y) = 2x\,\mathrm{e}^{2y}.$$

Interprétation. Comme pour une variable, la dérivée partielle donne une approximation de la variation de f : pour h petit,

$$f(a+h,b) - f(a,b) \simeq h\,\frac{\partial f}{\partial x}(a,b).$$

C'est l'effet d'une petite variation de x, *toutes choses égales par ailleurs*.

Exemple (productivités marginales). Pour la fonction de production $Q(K,L) = 10\sqrt{KL} = 10K^{1/2}L^{1/2}$,

$$\frac{\partial Q}{\partial K}(K,L) = 5K^{-1/2}L^{1/2} = 5\sqrt{\frac{L}{K}}, \qquad \frac{\partial Q}{\partial L}(K,L) = 5\sqrt{\frac{K}{L}}.$$

En $(K,L) = (4,9)$, on trouve $\partial_K Q(4,9) = 7{,}5$ et $\partial_L Q(4,9) = \frac{10}{3} \simeq 3{,}33$. Ce sont la **productivité marginale du capital** et la **productivité marginale du travail** : une unité de travail supplémentaire, à capital inchangé, augmente la production d'environ 3,33. On vérifie : $Q(4,10) = 10\sqrt{40} \simeq 63{,}25$, contre $60 + 3{,}33 = 63{,}33$ pour l'approximation.

Exemple (élasticités-prix et revenu). Pour la demande $D(p,R) = \dfrac{0{,}2\,R}{p}$,

$$\frac{\partial D}{\partial p}(p,R) = -\frac{0{,}2\,R}{p^2} < 0, \qquad \frac{\partial D}{\partial R}(p,R) = \frac{0{,}2}{p} > 0.$$

La demande diminue avec le prix et augmente avec le revenu.

Gradient

Les deux dérivées partielles se regroupent en un vecteur.

Définition (gradient). Soit f une fonction de deux variables admettant des dérivées partielles en (a,b). Le *gradient* de f en (a,b) est le vecteur

$$\nabla f(a,b) = \begin{pmatrix} \dfrac{\partial f}{\partial x}(a,b) \\ \dfrac{\partial f}{\partial y}(a,b) \end{pmatrix}.$$

Le gradient permet d'approcher la variation de f lorsque les *deux* variables bougent en même temps : on additionne les effets de chacune.

Proposition (approximation affine). Si f a des dérivées partielles continues, alors pour h et k petits,

$$f(a+h,b+k) \simeq f(a,b) + h\,\frac{\partial f}{\partial x}(a,b) + k\,\frac{\partial f}{\partial y}(a,b).$$

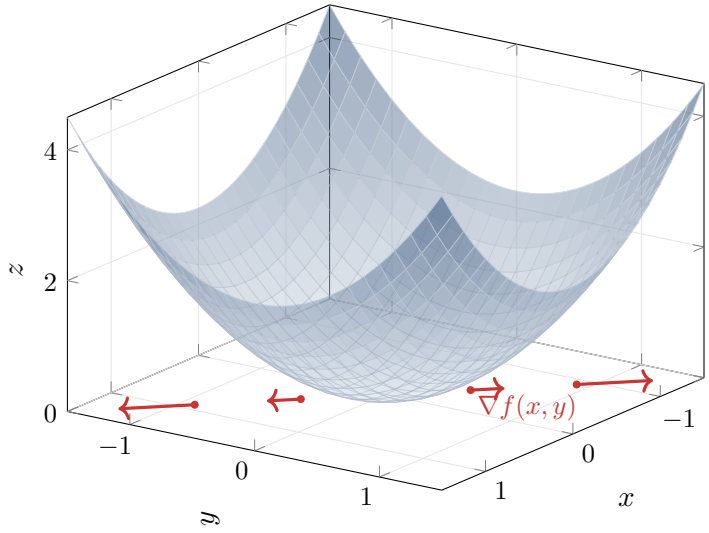
C'est la généralisation à deux variables de l'approximation $f(x+h) \simeq f(x) + hf'(x)$. Dans la formule ci-dessous, on voit apparaitre les deux composantes du gradient : $\frac{\partial f}{\partial x}$ et $\frac{\partial f}{\partial y}$.

Exemple. Pour $Q(K,L) = 10\sqrt{KL}$, on a $\nabla Q(4,9) = \begin{pmatrix} 7{,}5 \\ 10/3 \end{pmatrix}$. L'entreprise remplace 0,2 unité de travail par 0,2 unité de capital, et passe de $(4,9)$ à $(4{,}2\,;\,8{,}8)$:

$$Q(4{,}2\,;\,8{,}8) \simeq 60 + 0{,}2 \times 7{,}5 - 0{,}2 \times \frac{10}{3} \simeq 60{,}83.$$

La valeur exacte est $10\sqrt{36{,}96} \simeq 60{,}79$. La production augmente, car à ce point le capital est plus productif à la marge que le travail.

Interprétation géométrique. Pour $f(x,y) = x^2+y^2$, dont le graphe est le paraboloïde déjà rencontré, on a $\nabla f(x,y) = \begin{pmatrix} 2x \\ 2y \end{pmatrix}$. Sur la figure, on a placé quelques points (x,y) dans le plan horizontal et, en chacun d'eux, la flèche rouge représente le gradient $\nabla f(x,y)$: elle pointe à l'opposé de l'origine, vers les régions où la surface est plus haute.



Le gradient indique la direction dans laquelle il faut se déplacer pour que f augmente le plus vite : en le suivant, on gravit le « bol » par la ligne de plus grande pente. Sa longueur mesure la rapidité de cette augmentation : les flèches s'allongent à mesure que l'on s'éloigne de l'origine, là où la surface devient plus pentue. À l'inverse, $-\nabla f$ indique la direction de plus forte descente.

Points critiques. Au sommet d'une colline ou au fond d'une vallée, le sol est « plat » dans toutes les directions : les deux dérivées partielles s'annulent. On généralise ainsi la notion de point critique.

Définition. Un point (a,b) intérieur au domaine de f est un *point critique* de f si

$$\nabla f(a,b) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Proposition. Si f a des dérivées partielles continues et admet un extremum local en un point (a,b) intérieur à son domaine, alors (a,b) est un point critique de f.

Exemple. Pour $f(x,y) = x^2 + y^2$, l'équation $\nabla f(x,y) = 0$ donne $2x = 0$ et $2y = 0$: le seul point critique est $(0,0)$. Comme $f(x,y) \geq 0 = f(0,0)$ pour tout (x,y), c'est un minimum global, le fond du bol.

Remarque. Comme pour une variable, la réciproque est fausse : un point critique n'est pas toujours un extremum. On étudiera en TD comment reconnaître la nature d'un point critique, puis comment optimiser une fonction de deux variables sous contrainte.

À travailler. Exercices « Dérivées partielles et gradient » et « Fonction de production et rendements d'échelle » du TD 3.